

LAPORAN PROJECT CAPSTONE

DermaSight

(Skin Cancer Dataset Analysis and Preparation)



CC26-PSU233

DATA SCIENCE

CODING CAMP

POWERED BY DBS FOUNDATION

2026

KATA PENGANTAR

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga laporan proyek **“DermaSight: Intelligent Skin Disease Classification & Severity Scoring System”** ini dapat diselesaikan dengan baik.

Laporan ini disusun sebagai dokumentasi proses analisis data yang dilakukan untuk mendukung pengembangan sistem klasifikasi penyakit kulit berbasis Artificial Intelligence (AI). Proyek ini menggunakan dataset ISIC 2019 dengan fokus pada tiga kategori penyakit kulit, yaitu Melanoma (MEL), Melanocytic Nevi (NV), dan Basal Cell Carcinoma (BCC). Melalui tahapan data wrangling, exploratory data analysis (EDA), preprocessing, feature engineering, hingga data preparation, proyek ini bertujuan menghasilkan dataset yang bersih, terstruktur, dan siap digunakan pada tahap pengembangan model AI.

Penyusunan laporan ini diharapkan dapat memberikan gambaran yang jelas mengenai proses pengolahan data, analisis karakteristik penyakit kulit, serta berbagai langkah yang dilakukan untuk meningkatkan kualitas dataset sebelum digunakan pada proses modeling. Selain itu, laporan ini juga diharapkan dapat menjadi referensi dalam pengembangan sistem deteksi dini penyakit kulit berbasis teknologi kecerdasan buatan.

Penulis menyadari bahwa laporan ini masih memiliki keterbatasan dan masih dapat dikembangkan lebih lanjut. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan untuk penyempurnaan proyek di masa mendatang.

Akhir kata, penulis mengucapkan terima kasih kepada seluruh pihak yang telah memberikan dukungan dan kontribusi selama proses pengerjaan proyek ini.

Banjarnegara, 20 Mei 2026

Penulis



Sindi Prasetyani

CDCC414D6X1041 / CC26-PSU233

ABSTRAK

DermaSight pada *Data Science* merupakan proyek yang berfokus pada analisis dan persiapan dataset penyakit kulit berbasis citra medis untuk mendukung pengembangan sistem klasifikasi penyakit kulit berbasis *Artificial Intelligence* (AI). Dataset yang digunakan berasal dari *ISIC 2019* dan difokuskan pada tiga kelas utama, yaitu *Melanoma* (MEL), *Melanocytic Nevi* (NV), dan *Basal Cell Carcinoma* (BCC). Proses yang dilakukan meliputi *data wrangling*, *data cleaning*, *exploratory data analysis* (EDA), *preprocessing*, *feature engineering*, dan *data preparation*. Hasil *cleaning* menunjukkan bahwa *missing value* pada metadata berhasil ditangani, seluruh file citra tersedia, dan tidak ditemukan *corrupted image*. Setelah filtering kelas, dataset yang digunakan berjumlah 20.720 data. Hasil EDA menunjukkan adanya *class imbalance*, dengan kelas NV sebagai kelas mayoritas. Selain itu, metadata pasien seperti usia, jenis kelamin, dan lokasi anatomi lesi menunjukkan pola distribusi yang berbeda pada setiap kelas penyakit. Pada tahap akhir, dilakukan *leakage-aware splitting* berbasis *lesion_id* dan *undersampling* untuk menghasilkan dataset yang seimbang serta bebas *data leakage*. Dataset final terdiri dari 7.992 data *training*, 999 data *validation*, dan 978 data *testing* yang diekspor dalam format *train.csv*, *val.csv*, dan *test.csv*. Hasil proyek ini berupa dataset modeling yang bersih, terstruktur, seimbang, dan siap digunakan pada tahap pengembangan model.

Kata kunci: *DermaSight*, *ISIC 2019*, *Data Science*, penyakit kulit, citra medis,

ABSTRACT

DermaSight in Data Scientist is a project focused on analyzing and preparing a medical image-based skin disease dataset to support the development of an Artificial Intelligence (AI) based skin disease classification system. The dataset used in this project was obtained from ISIC 2019 and focused on three main classes Melanoma (MEL), Melanocytic Nevi (NV), and Basal Cell Carcinoma (BCC). The project workflow included data wrangling, data cleaning, exploratory data analysis (EDA), preprocessing, feature engineering, and data preparation. The cleaning process successfully handled missing values in the metadata, validated the availability of all image files, and confirmed that there were no corrupted images. After class filtering, the dataset consisted of 20,720 records. The EDA results showed a class imbalance, with NV as the majority class. In addition, patient metadata such as age, sex, and anatomical lesion site showed different distribution patterns across disease classes. In the final stage, leakage-aware splitting based on lesion_id and undersampling were applied to produce a balanced and leakage-free dataset. The final dataset consisted of 7,992 training data, 999 validation data, and 978 testing data, exported as train.csv, val.csv, and test.csv. The result of this project is a clean, structured, balanced modeling dataset that is ready to be used in the next stage of model development.

Keywords: DermaSight, ISIC 2019, Data Science, skin disease, medical image

DAFTAR ISI

KATA PENGANTAR.....	ii
ABSTRAK.....	iii
<i>ABSTRACT</i>	iv
DAFTAR ISI	v
DAFTAR TABEL.....	ix
DAFTAR GAMBAR	x
DAFTAR LAMPIRAN	xiii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah (<i>Business Questions</i>)	1
1.3 Tujuan Proyek	2
1.4 Ruang Lingkup Proyek	3
BAB II METODOLOGI PROYEK	4
2.1 Deskripsi <i>Dataset</i>	4
2.2 <i>Workflow</i> Proyek	4
2.3 <i>Data Wrangling</i>	5
2.3.1 <i>Data Gathering</i>	5
2.3.2 <i>Data Assessing</i>	5
2.4 Data Cleaning.....	6
2.5 <i>Exploratory Data Analysis</i> (EDA).....	8
2.6 <i>Explanatory Analysis</i> Berdasarkan <i>Business Questions</i>	9
2.7 <i>Preprocessing</i>	10
2.7.1 <i>Label Encoding</i>	11
2.7.2 <i>Image Preprocessing</i>	11
2.8 <i>Feature Engineering</i>	11
2.8.1 <i>Age Group</i>	12

2.8.2 Risk Category	12
2.8.3 Site Risk Score	13
2.9 Data Preparation	13
2.9.1 Leakage-Aware Splitting	14
2.9.2 Leakage Validation	14
2.9.3 Class Balancing dengan Undersampling	14
2.9.4 Dataset Modeling	15
2.9.5 Dataset Export	15
2.9.6 Final Dataset Summary	15
2.9.7 Data Dictionary	16
BAB III IMPLEMENTASI DAN HASIL	17
3.1 Data Wrangling	17
3.1.1 Data Gathering	17
3.1.2 Data Assessing	20
3.2 Data Cleaning	23
3.3 Exploratory Data Analysis	28
3.3.1 Analisis Distribusi Kelas Target	29
3.3.2 Analisis Distribusi Usia Pasien	30
3.3.3 Analisis Distribusi Jenis Kelamin	33
3.3.4 Analisis Distribusi Lokasi Anatomi Lesi	34
3.3.5 Analisis Ukuran Citra	35
3.3.6 Analisis <i>Brightness</i> dan RGB Citra	37
3.3.7 Analisis Hubungan <i>Metadata</i> dengan Kelas Target	39
3.4 Explanatory Analysis Berdasarkan <i>Business Questions</i>	41
3.4.1 Karakteristik Distribusi Penyakit Kulit Berdasarkan <i>Metadata</i> Pasien	42
3.4.2 Kondisi <i>Class Imbalance</i> pada <i>Dataset</i>	43

3.4.3 Profil Kualitas dan Karakteristik Citra Medis.....	44
3.4.4 Peran <i>Preprocessing</i> dan <i>Feature Engineering</i> dalam Meningkatkan Kualitas <i>Dataset</i>	45
3.5 <i>Preprocessing</i>	46
3.5.1 <i>Label Encoding</i> pada <i>Metadata</i>	46
3.5.2 <i>Image Preprocessing</i>	49
3.5.3 Hasil <i>Preprocessing</i>	51
3.6 <i>Feature Engineering</i>	52
3.6.1 Pembentukan Fitur <i>Age Group</i>	52
3.6.2 Pembentukan Fitur <i>Risk Category</i>	54
3.6.3 Pembentukan Fitur <i>Site Risk Score</i>	56
3.6.4 Analisis Hubungan Fitur Hasil <i>Feature Engineering</i>	58
3.7 <i>Data Preparation</i>	59
3.7.1 Analisis Duplikasi <i>Lesion ID</i>	60
3.7.2 <i>Leakage-Aware Splitting</i>	61
3.7.3 <i>Leakage Validation</i>	63
3.7.4 <i>Class Balancing</i> dengan <i>Undersampling</i>	65
3.7.5 Penyusunan <i>Dataset Modeling</i>	68
3.7.6 <i>Export Dataset</i>	70
3.8 <i>Final Dataset Summary</i> dan <i>Data Dictionary</i>	71
3.8.1 <i>Final Dataset Summary</i>	71
3.8.2 Struktur <i>Dataset Final</i>	73
3.8.3 Fitur yang Tidak Dimasukkan ke <i>Dataset Final</i>	74
BAB IV PENUTUP	75
4.1 Kesimpulan	75
4.2 Saran.....	75

DAFTAR PUSTAKA.....	77
LAMPIRAN.....	78

DAFTAR TABEL

Tabel 3. 1 Ringkasan jumlah data akhir pada setiap subset.	72
Tabel 3. 2 Struktur kolom pada dataset final.....	73

DAFTAR GAMBAR

Gambar 2. 1 <i>Workflow</i> Proyek	5
Gambar 3. 1 Hasil ekstraksi <i>dataset ISIC 2019</i>	17
Gambar 3. 2 Ukuran <i>metadata</i> dan <i>ground truth dataset ISIC 2019</i>	18
Gambar 3. 3 Sampel <i>metadata</i> dan <i>ground truth dataset</i>	18
Gambar 3. 4 Hasil penggabungan <i>metadata</i> dan <i>ground truth</i>	19
Gambar 3. 5 Hasil pembentukan label target diagnosis	19
Gambar 3. 6 Struktur dataset hasil penggabungan	20
Gambar 3. 7 Hasil pemeriksaan missing value pada dataset	21
Gambar 3. 8 Hasil pemeriksaan data duplikat	22
Gambar 3. 9 Hasil validasi keberadaan file citra	22
Gambar 3. 10 Hasil pemeriksaan <i>corrupted image</i>	23
Gambar 3. 11 Proses penanganan <i>missing value</i> pada <i>metadata</i>	24
Gambar 3. 12 Hasil pemeriksaan <i>missing value</i> setelah imputasi awal	25
Gambar 3. 13 Hasil validasi <i>missing value</i> setelah penanganan <i>lesion ID</i>	26
Gambar 3. 14 Hasil filtering <i>dataset</i> pada kelas MEL, NV, dan BCC	27
Gambar 3. 15 Ringkasan hasil <i>data cleaning</i> dan <i>class filtering</i>	28
Gambar 3. 16 Distribusi kelas target MEL, NV, dan BCC	29
Gambar 3. 17 Persentase kelas target dan <i>imbalance ratio</i>	30
Gambar 3. 18 <i>Age Approx</i>	31
Gambar 3. 19 Distribusi usia pasien	31
Gambar 3. 20 <i>Boxplot</i> usia pasien pada dataset	32
Gambar 3. 21 <i>Boxplot Age Approx</i>	32
Gambar 3. 22 Jumlah Distribusi jenis kelamin pasien	33
Gambar 3. 23 Distribusi jenis kelamin pasien	33
Gambar 3. 24 Jumlah Distribusi lokasi anatomi lesi	34
Gambar 3. 25 Distribusi lokasi anatomi lesi	34
Gambar 3. 26 Statistik ukuran citra medis	35
Gambar 3. 27 <i>Image height distribution</i>	36
Gambar 3. 28 <i>Image width distribution</i>	36
Gambar 3. 29 Jumlah variasi dimensi citra	37
Gambar 3. 30 Jumlah distribusi <i>brightness</i> citra	38

Gambar 3. 31 Distribusi <i>brightness</i> citra	38
Gambar 3. 32 Distribusi warna RGB pada citra	39
Gambar 3. 33 Hubungan usia pasien dengan kelas target.....	40
Gambar 3. 34 Hubungan jenis kelamin dengan kelas target.....	40
Gambar 3. 35 Hubungan lokasi anatomi lesi dengan kelas target	41
Gambar 3. 36 <i>Encode sex</i>	47
Gambar 3. 37 <i>Encode anatom_site_general</i>	47
Gambar 3. 38 <i>Encode target</i>	48
Gambar 3. 39 Sampel dataset setelah proses <i>label encoding</i>	49
Gambar 3. 40 Proses <i>resize</i> dan normalisasi citra.....	50
Gambar 3. 41 Perbandingan ukuran citra sebelum dan setelah <i>resize</i>	50
Gambar 3. 42 Hasil normalisasi nilai piksel citra	51
Gambar 3. 43 Hasil pembentukan fitur <i>age_group</i>	53
Gambar 3. 44 Distribusi kelompok usia pasien	53
Gambar 3. 45 Hasil <i>encoding</i> fitur <i>age_group</i>	54
Gambar 3. 46 Hasil pembentukan fitur <i>risk_category</i>	55
Gambar 3. 47 Distribusi kategori risiko penyakit	55
Gambar 3. 48 Proses pembentukan fitur <i>site_risk_score</i>	57
Gambar 3. 49 alidasi missing value pada <i>site_risk_score</i>	57
Gambar 3. 50 Hubungan <i>age_group</i> , <i>risk_category</i> , dan target	58
Gambar 3. 51 <i>Heatmap</i> korelasi fitur hasil <i>preprocessing</i> dan <i>feature engineering</i>	59
Gambar 3. 52 Duplikasi <i>Lesion ID</i>	60
Gambar 3. 53 Jumlah Maksimum citra per lesion	61
Gambar 3. 54 Proses <i>leakage-aware splitting</i> berbasis <i>lesion_id</i>	62
Gambar 3. 55 Jumlah data <i>train</i> , <i>validation</i> , dan <i>test</i> sebelum <i>balancing</i>	63
Gambar 3. 56 Hasil validasi <i>data leakage</i> antar subset	64
Gambar 3. 57 Distribusi kelas sebelum <i>undersampling</i>	65
Gambar 3. 58 Proses <i>class balancing</i> menggunakan <i>undersampling</i>	66
Gambar 3. 59 Jumlah data setelah <i>undersampling</i> pada setiap subset.....	67
Gambar 3. 60 Distribusi kelas final setelah <i>undersampling</i>	68
Gambar 3. 61 Struktur dataset modeling akhir	69

Gambar 3. 62 Hasil <i>export dataset train, validation, dan test</i>	70
Gambar 3. 63 Ringkasan jumlah data final pada setiap subset.....	71
Gambar 3. 64 Sampel struktur dataset final untuk modeling.....	72

DAFTAR LAMPIRAN

Lampiran 1 Streamlit Home.....	78
Lampiran 2 Steamlit Dashboard	78
Lampiran 3 Streamlit Dataset Overview	78
Lampiran 4 Bisuness Question Analysis.....	79
Lampiran 5 Streamlit Feature Engineering	79
Lampiran 6 Streamlit Correlation Analysis.....	79
Lampiran 7 Streamlit Data Preparation.....	80
Lampiran 8 Streamlit Dataset Documentation.....	80

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penyakit kulit merupakan salah satu masalah kesehatan yang sering diabaikan akibat kurangnya kesadaran masyarakat terhadap pentingnya deteksi dini. Akses terhadap dokter spesialis kulit di Indonesia juga masih sangat terbatas, khususnya bagi masyarakat yang berada di daerah non-perkotaan. Keterbatasan akses medis ini pada akhirnya mendorong banyak masyarakat untuk melakukan diagnosis mandiri yang justru berisiko tinggi memperburuk kondisi penyakit tersebut.

Perkembangan teknologi *Artificial Intelligence (AI)* membuka peluang besar untuk mengatasi keterbatasan tersebut melalui proses identifikasi penyakit kulit berbasis analisis citra medis. Pemanfaatan teknologi kecerdasan buatan ini memungkinkan klasifikasi lesi kulit dilakukan secara lebih cepat dan konsisten sebagai langkah skrining awal. Proyek *DermaSight (Intelligent Skin Disease Classification & Severity Scoring System)* kemudian dikembangkan sebagai inovasi sistem AI yang dirancang khusus untuk membedakan kategori diagnostik menggunakan *input* citra lesi kulit. Sistem cerdas ini turut dilengkapi dengan kemampuan memberikan *severity scoring* sebagai indikator tingkat keparahan awal guna mempermudah tenaga kesehatan dalam melakukan proses *triase* medis.

Pengembangan sistem deteksi dini pada proyek DermaSight ini sepenuhnya menggunakan sumber data Kaggle ISIC 2019. Kumpulan observasi medis ini terpilih karena statusnya sebagai *dataset benchmark* standar internasional untuk klasifikasi penyakit kulit berbasis AI yang terbukti memiliki volume data besar serta kualitas citra yang sangat baik. Keunggulan utama dari dataset ini juga terletak pada ketersediaan metadata pendukung pasien yang sangat komprehensif, seperti usia, jenis kelamin (*gender*), dan lokasi anatomi lesi (*anatomical site*), yang seluruhnya sangat relevan untuk menyempurnakan performa analisis sistem AI.

1.2 Rumusan Masalah (*Business Questions*)

Berdasarkan latar belakang yang telah diuraikan, proyek ini diarahkan untuk menjawab empat rumusan masalah utama yaitu:

- a. Bagaimana karakteristik distribusi kelas *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)* jika ditinjau berdasarkan metadata pasien seperti usia, jenis kelamin, dan lokasi anatomi lesi?
- b. Apakah terdapat ketidakseimbangan distribusi kelas (*class imbalance*) pada *dataset Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)* yang dapat berdampak pada performa model klasifikasi AI nantinya?
- c. Bagaimana profil kualitas serta karakteristik citra medis pada *dataset Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)* yang akan dijadikan input untuk pengembangan model AI?
- d. Bagaimana implementasi proses *preprocessing* dan *feature engineering* dapat membantu meningkatkan kualitas *dataset* serta mendukung analisis mendalam terkait karakteristik kelas *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)*?

1.3 Tujuan Proyek

Proyek DermaSight bertujuan untuk melakukan analisis dan persiapan *dataset* penyakit kulit berbasis citra medis guna mendukung pengembangan model klasifikasi penyakit kulit menggunakan *Artificial Intelligence (AI)*. Secara khusus, tujuan proyek ini adalah:

- a. Menganalisis karakteristik distribusi *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)* berdasarkan metadata pasien.
- b. Mengidentifikasi kondisi *class imbalance* pada *dataset* yang berpotensi memengaruhi performa model klasifikasi.
- c. Mengevaluasi kualitas dan karakteristik citra medis yang digunakan pada proses pengembangan model.
- d. Melakukan *preprocessing* untuk meningkatkan kualitas dan konsistensi data.
- e. Melakukan *feature engineering* untuk menghasilkan representasi data yang lebih informatif.
- f. Mempersiapkan *dataset* modeling yang bersih, terstruktur, seimbang, dan bebas data *leakage* sehingga siap digunakan pada tahap pengembangan model AI.

1.4 Ruang Lingkup Proyek

Ruang lingkup proyek DermaSight dibatasi pada proses analisis dan persiapan *dataset* penyakit kulit menggunakan *dataset* ISIC 2019. Batasan yang diterapkan pada proyek ini meliputi:

- a. *Dataset* yang digunakan berasal dari ISIC 2019.
- b. Analisis difokuskan pada tiga kelas penyakit kulit, yaitu *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)*.
- c. Proyek mencakup tahapan data *wrangling*, *exploratory data analysis (EDA)*, *preprocessing*, *feature engineering*, dan *data preparation*.
- d. *Output* utama proyek berupa *dataset* modeling yang siap digunakan untuk pengembangan model AI.
- e. Pengembangan, pelatihan, dan evaluasi model AI tidak termasuk dalam ruang lingkup proyek *data science* ini.

BAB II

METODOLOGI PROYEK

2.1 Deskripsi Dataset

Proyek DermaSight menggunakan *dataset* ISIC 2019 (*International Skin Imaging Collaboration* 2019) yang diperoleh melalui platform Kaggle. *Dataset* ini merupakan salah satu *dataset benchmark* internasional yang banyak digunakan dalam penelitian dan pengembangan sistem klasifikasi penyakit kulit berbasis *Artificial Intelligence (AI)*.

Dataset ISIC 2019 menyediakan citra lesi kulit beserta *metadata* pendukung yang meliputi informasi usia pasien, jenis kelamin, lokasi anatomi lesi, identitas lesi, serta label diagnosis penyakit kulit. Kombinasi antara data citra dan *metadata* tersebut memungkinkan dilakukannya analisis karakteristik penyakit kulit secara lebih komprehensif.

Pada proyek ini, analisis difokuskan pada tiga kelas utama, yaitu *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)*, yang dipilih sebagai ruang lingkup pengembangan sistem klasifikasi penyakit kulit berbasis AI.

2.2 Workflow Proyek

Proyek DermaSight dilaksanakan menggunakan pendekatan data *science* yang terstruktur mulai dari tahap pemahaman masalah hingga persiapan *dataset* untuk kebutuhan pengembangan model AI. Tahapan yang dilakukan dalam proyek ini meliputi:



Gambar 2. 1 Workflow Proyek

Setiap tahapan memiliki tujuan yang berbeda dan saling berkaitan untuk menghasilkan *dataset* yang bersih, terstruktur, dan siap digunakan pada tahap pengembangan model AI.

2.3 Data Wrangling

Data wrangling merupakan proses awal yang dilakukan untuk memahami struktur *dataset*, mengevaluasi kualitas data, serta melakukan pembersihan data sebelum digunakan pada tahap analisis.

2.3.1 Data Gathering

Tahap *data gathering* dilakukan dengan mengumpulkan *metadata* pasien dan citra lesi kulit yang tersedia pada *dataset* ISIC 2019.

Metadata yang digunakan meliputi informasi usia pasien, jenis kelamin, lokasi anatomi lesi, identitas lesi, serta label diagnosis penyakit kulit. Selain itu, citra medis lesi kulit digunakan sebagai sumber data utama untuk mendukung pengembangan sistem klasifikasi penyakit kulit berbasis AI.

2.3.2 Data Assessing

Tahap *data assessing* dilakukan untuk memahami karakteristik *dataset* serta mengevaluasi kualitas data sebelum memasuki proses pembersihan (*data cleaning*). Proses ini bertujuan untuk mengidentifikasi berbagai permasalahan yang berpotensi

memengaruhi hasil analisis maupun performa model AI yang akan dikembangkan. Pemeriksaan dilakukan terhadap beberapa aspek utama sebagai berikut:

- a. Struktur *Dataset*, untuk mengetahui jumlah data, jumlah fitur, tipe data, serta memahami informasi yang tersedia pada setiap atribut.
- b. *Missing Value Analysis*, untuk mengidentifikasi fitur yang memiliki data tidak lengkap sehingga dapat ditentukan metode penanganan yang paling sesuai pada tahap *data cleaning*.
- c. *Duplicate Data Analysis*, untuk memastikan tidak terdapat data duplikat yang dapat menyebabkan bias pada proses analisis maupun pemodelan.
- d. *Image Path Validation*, untuk memastikan setiap *metadata* memiliki file citra yang sesuai dan dapat diakses selama proses pengolahan data.
- e. *Image Integrity Validation*, untuk memeriksa apakah terdapat file citra yang rusak (*corrupted image*) sehingga berpotensi mengganggu proses *preprocessing* maupun *training* model.
- f. *Dataset Consistency Check*, untuk memastikan hubungan antara *metadata* dan citra tetap konsisten sebelum digunakan pada tahap analisis lebih lanjut.

Hasil dari proses *data assessing* digunakan sebagai dasar dalam menentukan strategi pembersihan data, termasuk penanganan *missing value*, validasi kualitas citra, serta penyaringan data yang sesuai dengan ruang lingkup proyek DermaSight. Dengan demikian, *dataset* yang digunakan pada tahap berikutnya memiliki kualitas yang lebih baik dan siap untuk dianalisis lebih lanjut.

2.4 Data Cleaning

Tahap *data cleaning* dilakukan untuk meningkatkan kualitas *dataset* dengan menangani permasalahan yang ditemukan pada proses *data assessing*. Tujuan utama dari tahap ini adalah memastikan data yang digunakan memiliki struktur yang lebih konsisten, meminimalkan kehilangan informasi, serta siap digunakan pada proses analisis dan pengembangan model AI.

- a. Penanganan *Missing Value* pada Fitur Numerik

Missing value pada fitur *age_approx* ditangani menggunakan metode *imputasi* median. Pendekatan ini dipilih karena median lebih *robust* terhadap keberadaan *outlier* dibandingkan nilai rata-rata (*mean*), sehingga

mampu mempertahankan karakteristik distribusi usia pasien tanpa memberikan pengaruh yang terlalu besar dari nilai ekstrem.

b. Penanganan *Missing Value* pada Fitur Kategorikal

Missing value pada fitur kategorikal seperti *sex* dan *anatom_site_general* diisi menggunakan kategori khusus *unknown*. Pendekatan ini dipilih untuk mempertahankan seluruh observasi pada *dataset* tanpa harus menghapus data yang masih memiliki informasi penting pada fitur lainnya. Selain itu, kategori *unknown* juga memungkinkan model maupun proses analisis mengenali bahwa informasi tersebut memang tidak tersedia pada data asli.

c. Penanganan *Missing Value* pada *Lesion ID*

Fitur *lesion_id* memiliki peran penting karena digunakan sebagai identitas unik lesi kulit dan menjadi dasar dalam proses *leakage-aware splitting*. Oleh karena itu, *missing value* pada kolom ini tidak dihapus, melainkan diberikan *identifier* baru dengan format *unknown_lesion_x*. Pendekatan ini memastikan setiap observasi tetap memiliki identitas lesi yang unik sehingga integritas *dataset* tetap terjaga selama proses analisis dan pembagian data.

d. Penyaringan Kelas Penyakit

Dataset ISIC 2019 menyediakan beberapa kategori penyakit kulit. Namun, sesuai ruang lingkup proyek DermaSight, hanya tiga kelas yang digunakan, yaitu *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)*. Proses *filtering* dilakukan untuk memfokuskan analisis pada penyakit yang paling relevan dengan tujuan pengembangan sistem klasifikasi kanker kulit berbasis AI sekaligus mengurangi kompleksitas klasifikasi multi-kelas.

e. Validasi Hasil *Cleaning*

Setelah seluruh proses pembersihan data selesai dilakukan, *dataset* divalidasi kembali untuk memastikan bahwa seluruh *missing value* telah tertangani dengan baik, struktur data tetap konsisten, dan tidak terdapat perubahan yang dapat mengganggu proses analisis maupun tahapan selanjutnya.

Melalui serangkaian proses tersebut, *dataset* menjadi lebih bersih, konsisten, dan siap digunakan pada tahap *exploratory data analysis (EDA)*, *preprocessing*, *feature engineering*, serta *data preparation*.

2.5 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dataset serta memperoleh gambaran awal mengenai pola distribusi data sebelum memasuki tahap *preprocessing* dan *feature engineering*. Tahap ini bertujuan untuk mengidentifikasi karakteristik metadata pasien, distribusi kelas penyakit kulit, kualitas citra medis, serta hubungan antar variabel yang berpotensi memberikan informasi penting bagi proses analisis dan pengembangan model AI.

Pada penelitian ini, EDA dilakukan melalui analisis distribusi kelas target untuk mengetahui proporsi masing-masing kategori penyakit kulit yang digunakan dalam proyek DermaSight, yaitu *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)*. Analisis ini membantu mengidentifikasi kondisi class imbalance yang dapat memengaruhi proses pengembangan model.

Selain itu, dilakukan analisis terhadap karakteristik pasien berdasarkan metadata yang tersedia pada dataset, meliputi distribusi usia pasien, distribusi jenis kelamin, serta distribusi lokasi anatomi lesi. Analisis tersebut bertujuan untuk memahami karakteristik demografis dan pola kemunculan lesi kulit pada berbagai bagian tubuh.

EDA juga mencakup analisis karakteristik citra medis yang digunakan dalam penelitian. Analisis dilakukan terhadap ukuran citra, distribusi dimensi gambar, tingkat kecerahan (*brightness*), serta distribusi kanal warna RGB untuk memperoleh pemahaman mengenai kualitas dan karakteristik visual dataset. Informasi ini digunakan sebagai dasar dalam menentukan strategi *preprocessing* citra pada tahap selanjutnya.

Selain analisis univariat, dilakukan pula analisis hubungan antara metadata pasien dengan kelas target penyakit kulit. Analisis ini bertujuan untuk mengidentifikasi keterkaitan antara usia pasien, jenis kelamin, dan lokasi anatomi lesi terhadap distribusi kelas *Melanoma (MEL)*, *Melanocytic Nevi (NV)*, dan *Basal Cell Carcinoma (BCC)*. Hasil dari keseluruhan proses EDA digunakan sebagai

dasar dalam menentukan langkah *preprocessing*, *feature engineering*, serta data preparation yang sesuai dengan karakteristik dataset.

2.6 Explanatory Analysis Berdasarkan Business Questions

Setelah proses *Exploratory Data Analysis* (EDA) dilakukan, tahap berikutnya adalah *explanatory analysis* berdasarkan *business questions* yang telah ditentukan pada fase *business understanding*. Tahap ini bertujuan untuk menginterpretasikan karakteristik dataset secara lebih terarah dengan fokus pada permasalahan yang ingin dijawab dalam proyek DermaSight. Analisis dilakukan menggunakan berbagai visualisasi data dan pendekatan eksploratif untuk menghasilkan pemahaman yang lebih mendalam mengenai karakteristik penyakit kulit, kualitas dataset, serta dampak proses pengolahan data yang telah dilakukan.

Explanatory analysis pertama difokuskan pada identifikasi karakteristik distribusi penyakit kulit berdasarkan metadata pasien. Analisis dilakukan menggunakan atribut usia pasien, jenis kelamin, dan lokasi *anatomi lesi* untuk memahami pola distribusi *Melanoma* (MEL), *Melanocytic Nevi* (NV), dan *Basal Cell Carcinoma* (BCC). Pendekatan ini digunakan untuk mengetahui bagaimana karakteristik pasien berkaitan dengan masing-masing kategori penyakit kulit.

Selanjutnya dilakukan analisis terhadap kondisi class imbalance pada dataset. Analisis ini bertujuan untuk mengevaluasi keseimbangan distribusi jumlah data antar kelas penyakit kulit serta mengidentifikasi potensi pengaruhnya terhadap proses pengembangan model AI. Hasil analisis ini digunakan sebagai dasar dalam menentukan strategi penanganan ketidakseimbangan kelas pada tahap data preparation.

Selain metadata pasien, *explanatory analysis* juga dilakukan terhadap kualitas dan karakteristik citra medis yang digunakan dalam penelitian. Analisis mencakup pemeriksaan dimensi citra, distribusi ukuran gambar, tingkat kecerahan (*brightness*), serta distribusi kanal warna RGB. Tahap ini bertujuan untuk memahami karakteristik visual dataset dan mendukung penentuan strategi *preprocessing* citra yang sesuai.

Explanatory analysis terakhir difokuskan pada evaluasi peran *preprocessing* dan *feature engineering* dalam meningkatkan kualitas dataset. Analisis dilakukan terhadap hasil penanganan *missing value*, proses *encoding*, pembentukan fitur

turunan seperti *age_group*, *risk_category*, dan *site_risk_score*, serta hubungan antar fitur yang dihasilkan. Tahap ini bertujuan untuk memastikan bahwa proses pengolahan data memberikan representasi yang lebih informatif dan mendukung kebutuhan analisis maupun persiapan dataset untuk pengembangan model AI.

Melalui *explanatory analysis* berdasarkan *business questions*, diperoleh pemahaman yang lebih terstruktur mengenai karakteristik dataset dan efektivitas proses pengolahan data yang telah dilakukan. Hasil analisis ini kemudian menjadi dasar dalam tahap data *preparation* untuk menghasilkan dataset yang siap digunakan pada proses pengembangan model *Artificial Intelligence*.

2.7 Preprocessing

Tahap *preprocessing* dilakukan untuk mempersiapkan *dataset* agar memiliki kualitas yang lebih baik serta sesuai digunakan pada proses analisis maupun pengembangan model *Artificial Intelligence (AI)*. Data mentah yang diperoleh dari sumber *dataset* umumnya masih memiliki berbagai keterbatasan, seperti adanya *missing value*, fitur kategorikal yang belum dapat diproses secara numerik, serta variasi karakteristik citra yang perlu diseragamkan sebelum digunakan pada tahap modeling.

Pada proyek DermaSight, *preprocessing* tidak hanya bertujuan untuk meningkatkan kualitas data, tetapi juga untuk memastikan bahwa seluruh informasi yang tersedia pada *dataset* dapat dimanfaatkan secara optimal tanpa menimbulkan bias maupun inkonsistensi selama proses analisis. Tahapan ini menjadi langkah penting karena kualitas data yang baik akan berpengaruh langsung terhadap kualitas *insight* yang dihasilkan serta kesiapan *dataset* untuk digunakan pada pengembangan model AI.

Secara umum, *preprocessing* pada proyek ini mencakup penanganan *missing value*, transformasi fitur kategorikal ke dalam bentuk numerik, serta *preprocessing* citra medis untuk menghasilkan format data yang lebih konsisten. Melalui proses ini, *dataset* diharapkan memiliki struktur yang lebih terstandarisasi, mudah dianalisis, dan siap digunakan pada tahapan *feature engineering* maupun data *preparation*.

2.7.1 Label Encoding

Beberapa fitur pada *dataset* masih berbentuk kategorikal sehingga belum dapat digunakan secara langsung pada proses analisis numerik maupun pengembangan model *machine learning*. Oleh karena itu, dilakukan proses label *encoding* untuk mengubah kategori teks menjadi representasi numerik yang lebih mudah diproses oleh algoritma komputasi.

Transformasi ini dilakukan pada fitur-fitur yang relevan seperti jenis kelamin, lokasi anatomi lesi, kategori risiko, serta label target. Hasil *encoding* memungkinkan proses analisis statistik, visualisasi hubungan antar fitur, dan pembentukan fitur baru dilakukan secara lebih efektif.

2.7.2 Image Preprocessing

Selain *metadata* pasien, proyek DermaSight juga memanfaatkan citra medis sebagai sumber data utama dalam pengembangan sistem klasifikasi penyakit kulit. Oleh karena itu, dilakukan analisis terhadap karakteristik citra untuk memahami kondisi data sebelum digunakan pada tahap pengembangan model AI.

Pada tahap ini, dilakukan eksplorasi terhadap ukuran citra (*image size*) yang tersedia pada *dataset* serta simulasi *preprocessing* citra berupa *resize* dan normalisasi piksel pada beberapa sampel gambar. Tujuan dari proses ini adalah untuk memahami bagaimana *preprocessing* citra dapat membantu menghasilkan format gambar yang lebih konsisten ketika digunakan pada proses modeling.

Perlu diperhatikan bahwa proses *resize* dan normalisasi pada tahap ini hanya digunakan untuk kebutuhan analisis dan visualisasi. Seluruh citra pada *dataset* tidak diubah secara permanen karena *preprocessing* citra secara penuh akan dilakukan pada *pipeline* pengembangan model AI pada tahap berikutnya.

Melalui analisis ini, diperoleh pemahaman mengenai karakteristik citra medis yang tersedia pada *dataset* serta kebutuhan *preprocessing* yang akan diterapkan pada proses modeling.

2.8 Feature Engineering

Feature engineering merupakan proses pembentukan fitur baru berdasarkan informasi yang telah tersedia pada *dataset* untuk menghasilkan representasi data yang lebih informatif. Tahap ini dilakukan setelah proses *preprocessing* selesai

sehingga data yang digunakan telah memiliki kualitas yang lebih baik dan siap untuk ditransformasikan.

Pada proyek DermaSight, *feature engineering* dilakukan untuk memperkaya informasi *metadata* pasien yang tersedia pada *dataset* ISIC 2019. Beberapa atribut asli pada *dataset* masih berupa informasi mentah yang kurang optimal apabila digunakan secara langsung untuk analisis karakteristik penyakit kulit. Oleh karena itu, dilakukan pembentukan fitur baru yang dapat membantu menyederhanakan interpretasi data, mengidentifikasi pola distribusi penyakit, serta menyediakan representasi *metadata* yang lebih terstruktur.

Fitur-fitur yang dihasilkan pada tahap ini tidak hanya digunakan untuk mendukung proses *exploratory data analysis (EDA)* dan *explanatory analysis*, tetapi juga dipersiapkan sebagai informasi tambahan yang berpotensi dimanfaatkan pada tahap pengembangan sistem klasifikasi penyakit kulit dan *severity scoring* berbasis *Artificial Intelligence (AI)*.

Melalui proses *feature engineering*, *dataset* diharapkan mampu memberikan gambaran yang lebih jelas mengenai hubungan antara karakteristik pasien, lokasi lesi, dan tingkat risiko penyakit kulit yang menjadi fokus proyek DermaSight.

2.8.1 Age Group

Fitur *age_group* dibentuk berdasarkan atribut *age_approx* dengan mengelompokkan usia pasien ke dalam beberapa kategori umur tertentu. Pengelompokan ini dilakukan untuk menyederhanakan analisis distribusi usia sehingga pola karakteristik penyakit kulit dapat diamati secara lebih mudah dibandingkan menggunakan usia numerik secara langsung.

Selain membantu proses interpretasi data, fitur ini juga mempermudah identifikasi kelompok usia yang lebih sering ditemukan pada masing-masing kategori penyakit kulit.

2.8.2 Risk Category

Fitur *risk_category* dibentuk dengan mengelompokkan kelas penyakit berdasarkan tingkat risiko medisnya. Pendekatan ini digunakan untuk menghasilkan representasi yang lebih sederhana mengenai tingkat keparahan penyakit yang terdapat pada *dataset*.

Pembentukan fitur ini bertujuan untuk mendukung analisis distribusi penyakit berdasarkan kelompok risiko serta membantu proses eksplorasi karakteristik pasien pada kategori risiko yang berbeda. Dengan adanya fitur ini, analisis dapat dilakukan tidak hanya berdasarkan kelas penyakit individual, tetapi juga berdasarkan kelompok risiko yang lebih umum.

2.8.3 Site Risk Score

Fitur *site_risk_score* dibentuk berdasarkan informasi lokasi anatomi lesi (*anatom_site_general*) dengan mengonversi kategori lokasi tersebut ke dalam representasi numerik berupa skor risiko.

Pembentukan fitur ini didasarkan pada asumsi bahwa beberapa lokasi anatomi memiliki tingkat perhatian klinis yang berbeda sehingga informasi lokasi lesi perlu direpresentasikan dalam bentuk yang lebih terstruktur. Melalui pendekatan ini, setiap lokasi anatomi memperoleh nilai risiko relatif yang dapat digunakan untuk mendukung analisis karakteristik penyakit kulit.

Berbeda dengan fitur *age_group* dan *risk_category* yang lebih berorientasi pada kebutuhan interpretasi dan eksplorasi data, fitur *site_risk_score* juga dipersiapkan sebagai *metadata* numerik yang dapat dimanfaatkan pada tahap pengembangan model AI maupun pengembangan sistem *severity scoring* pada proyek DermaSight.

2.9 Data Preparation

Data preparation merupakan tahapan akhir dalam proses pengolahan data yang bertujuan menghasilkan *dataset* yang bersih, terstruktur, dan siap digunakan pada tahap pengembangan model *Artificial Intelligence (AI)*. Setelah melalui proses data *wrangling*, *exploratory data analysis (EDA)*, *preprocessing*, dan *feature engineering*, *dataset* perlu dipersiapkan lebih lanjut agar sesuai dengan kebutuhan proses *training*, *validation*, dan *testing* model.

Pada proyek DermaSight, data *preparation* tidak hanya berfokus pada pembagian data, tetapi juga mencakup berbagai langkah untuk menjaga kualitas *dataset*, mengurangi potensi bias, serta memastikan bahwa proses evaluasi model dapat dilakukan secara objektif. Tahapan ini menjadi sangat penting karena kualitas data yang digunakan pada proses modeling akan berpengaruh langsung terhadap performa dan reliabilitas model yang dikembangkan.

Secara umum, *data preparation* pada proyek ini meliputi proses *leakage-aware splitting*, validasi data *leakage*, penyeimbangan distribusi kelas melalui *undersampling*, penyusunan *dataset* modeling, serta dokumentasi *dataset* melalui final *dataset summary* dan *data dictionary*.

2.9.1 Leakage-Aware Splitting

Tahap pertama dalam data *preparation* adalah pembagian *dataset* ke dalam *subset training*, *validation*, dan *testing*. Pembagian data dilakukan menggunakan pendekatan *leakage-aware splitting* berbasis *lesion_id*.

Pendekatan ini dipilih karena pada *dataset* ISIC 2019 terdapat kemungkinan satu lesi kulit memiliki lebih dari satu citra. Apabila gambar yang berasal dari lesi yang sama tersebar ke *subset* yang berbeda, model dapat memperoleh informasi yang seharusnya tidak tersedia pada proses evaluasi sehingga menghasilkan performa yang terlalu optimistis (*data leakage*).

Dengan menggunakan *lesion_id* sebagai dasar pembagian data, seluruh gambar yang berasal dari lesi yang sama akan ditempatkan pada *subset* yang sama. Pendekatan ini membantu menghasilkan proses evaluasi model yang lebih realistis dan merepresentasikan kondisi penggunaan model pada data baru yang belum pernah dilihat sebelumnya.

2.9.2 Leakage Validation

Setelah proses pembagian data selesai dilakukan, dilakukan validasi untuk memastikan bahwa tidak terdapat lesi yang sama pada *subset training*, *validation*, dan *testing*.

Proses validasi dilakukan dengan membandingkan identitas lesi pada setiap *subset* sehingga dapat dipastikan bahwa seluruh *subset* benar-benar independen satu sama lain. Tahapan ini merupakan langkah penting untuk menjamin integritas proses evaluasi model dan memastikan bahwa strategi *leakage-aware splitting* telah berjalan sesuai tujuan.

2.9.3 Class Balancing dengan Undersampling

Dataset penyakit kulit umumnya memiliki distribusi kelas yang tidak seimbang (*class imbalance*), di mana beberapa kelas memiliki jumlah data yang jauh lebih banyak dibandingkan kelas lainnya. Kondisi tersebut dapat menyebabkan

model lebih cenderung mempelajari pola dari kelas mayoritas dan mengabaikan kelas minoritas.

Untuk mengurangi potensi bias tersebut, dilakukan proses *undersampling* setelah tahap *splitting* selesai dilakukan. *Undersampling* diterapkan pada masing-masing *subset* secara terpisah sehingga keseimbangan distribusi kelas dapat ditingkatkan tanpa menimbulkan risiko data *leakage* antar *subset*.

Penerapan *undersampling* setelah *splitting* merupakan keputusan yang penting karena menjaga *independensi* data sekaligus memastikan bahwa proses *balancing* tidak menyebabkan informasi dari *subset* lain tercampur ke dalam data *training*.

2.9.4 Dataset Modeling

Setelah proses *balancing* selesai dilakukan, *dataset* disusun kembali ke dalam format yang lebih sesuai untuk kebutuhan pengembangan model AI.

Tahap ini mencakup pemilihan atribut yang relevan untuk proses modeling, penyusunan struktur *dataset* yang lebih sederhana, serta penyesuaian nama atribut agar lebih mudah dipahami dan digunakan pada *pipeline* pengembangan model. Selain informasi identitas gambar dan label kelas, *dataset* modeling juga mempertahankan *metadata* yang dianggap relevan untuk mendukung proses pengembangan sistem klasifikasi maupun *severity scoring*.

Melalui tahap ini, dihasilkan *dataset* modeling yang lebih ringkas, terstruktur, dan fokus pada informasi yang diperlukan pada proses pengembangan model.

2.9.5 Dataset Export

Dataset modeling yang telah selesai dipersiapkan kemudian diekspor ke dalam format yang dapat digunakan secara langsung pada tahap pengembangan model AI.

Proses ekspor dilakukan secara terpisah untuk masing-masing *subset* *training*, *validation*, dan *testing* sehingga memudahkan integrasi dengan *pipeline* modeling yang digunakan oleh tim pengembangan AI. Pemisahan *dataset* juga membantu menjaga konsistensi struktur data selama proses *training* dan evaluasi model.

2.9.6 Final Dataset Summary

Sebagai bagian dari dokumentasi data, dilakukan penyusunan ringkasan dataset akhir (*final dataset summary*). Ringkasan ini digunakan untuk memberikan

gambaran mengenai struktur *dataset* yang telah dipersiapkan, termasuk jumlah data pada setiap *subset* serta kesiapan dataset untuk digunakan pada proses modeling.

Tahapan ini juga berfungsi sebagai validasi akhir untuk memastikan bahwa seluruh proses data *preparation* telah berjalan sesuai dengan tujuan proyek.

2.9.7 Data Dictionary

Tahap terakhir dalam data *preparation* adalah penyusunan data *dictionary* sebagai dokumentasi fitur yang terdapat pada *dataset* modeling. Data *dictionary* berisi informasi mengenai nama atribut, deskripsi fitur, serta tipe data yang digunakan pada setiap kolom. Dokumentasi ini bertujuan meningkatkan keterbacaan *dataset*, mempermudah proses kolaborasi antar anggota tim, serta memastikan bahwa seluruh fitur yang digunakan pada tahap modeling memiliki definisi yang jelas dan konsisten.

Melalui data *dictionary*, dataset akhir menjadi lebih mudah dipahami, dikelola, dan digunakan pada proses pengembangan sistem *Artificial Intelligence* yang menjadi tujuan utama proyek DermaSight.

BAB III


IMPLEMENTASI DAN HASIL

3.1 *Data Wrangling*

Data wrangling merupakan tahap awal yang dilakukan untuk mengumpulkan, menggabungkan, dan memeriksa kualitas *dataset* sebelum masuk ke tahap analisis lebih lanjut. Pada proyek *DermaSight*, tahap ini dilakukan untuk memastikan bahwa data *metadata* pasien, label diagnosis, dan citra lesi kulit dari *dataset ISIC 2019* dapat digunakan secara konsisten dalam proses analisis dan persiapan *dataset modelling*. Proses *data wrangling* meliputi *data gathering* dan *data assessing*, mulai dari pemuatan *dataset*, penggabungan *metadata* dengan *ground truth*, pembentukan label target, hingga validasi kualitas data dan keberadaan file citra.

3.1.1 *Data Gathering*

Tahap *data gathering* diawali dengan pengunduhan *dataset ISIC 2019* melalui *Kaggle* menggunakan *Google Colaboratory*. *Dataset* yang diperoleh kemudian diekstrak dan disimpan ke dalam *Google Drive* agar proses pengolahan data dapat dilakukan secara lebih terstruktur. Setelah proses ekstraksi selesai, *dataset* terdiri dari tiga komponen utama, yaitu file *metadata*, file *ground truth*, dan folder citra lesi kulit.



```
[ ] #Download Dataset
!kaggle datasets download -d andrewmvd/isic-2019

... Dataset URL: https://www.kaggle.com/datasets/andrewmvd/isic-2019
License(s): Attribution-NonCommercial 4.0 International (CC BY-NC 4.0)
Downloading isic-2019.zip to /content
100% 9.10G/9.10G [01:16<00:00, 127MB/s]

[ ] #Extract Dataset
!unzip isic-2019.zip -d isic_2019

> ... Show hidden output

[ ] #Cek Isi Dataset
os.listdir('isic_2019')

['ISIC_2019_Training_GroundTruth.csv',
 'ISIC_2019_Training_Metadatas.csv',
 'ISIC_2019_Training_Input']
```

Gambar 3. 1 Hasil ekstraksi *dataset ISIC 2019*

Metadata pasien dimuat dari file *ISIC_2019_Training_Metadata.csv*, sedangkan label diagnosis dimuat dari file *ISIC_2019_Training_GroundTruth.csv*. Berdasarkan hasil pengecekan awal, *metadata* memiliki ukuran 25.331 baris dan 5 kolom, sedangkan *ground truth* memiliki ukuran 25.331 baris dan 10 kolom.

```
[ ] #Cek Shape
print("Metadata Shape :", metadata_df.shape)
print("Groundtruth Shape :", groundtruth_df.shape)

Metadata Shape : (25331, 5)
Groundtruth Shape : (25331, 10)
```

Gambar 3. 2 Ukuran *metadata* dan *ground truth* dataset ISIC 2019

Metadata berisi informasi pendukung seperti nama citra, usia pasien, lokasi anatomi lesi, lesion ID, dan jenis kelamin. Sementara itu, *ground truth* berisi label diagnosis penyakit dalam bentuk *one-hot encoding*, seperti MEL, NV, BCC, AK, BKL, DF, VASC, SCC, dan UNK.

```
[ ] #Sample Data m
metadata_df.head()

...      image  age_approx  anatom_site_general  lesion_id  sex
0  ISIC_0000000      55.0      anterior torso      NaN  female
1  ISIC_0000001      30.0      anterior torso      NaN  female
2  ISIC_0000002      60.0      upper extremity      NaN  female
3  ISIC_0000003      30.0      upper extremity      NaN   male
4  ISIC_0000004      80.0      posterior torso      NaN   male

[ ] #Sample Data g
groundtruth_df.head()

...      image  MEL  NV  BCC  AK  BKL  DF  VASC  SCC  UNK
0  ISIC_0000000  0.0  1.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0
1  ISIC_0000001  0.0  1.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0
2  ISIC_0000002  1.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0
3  ISIC_0000003  0.0  1.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0
4  ISIC_0000004  1.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0  0.0
```

Gambar 3. 3 Sampel *metadata* dan *ground truth* dataset

Kedua *dataset* telah berhasil dimuat, *metadata* dan *ground truth* digabungkan menggunakan kolom *image* sebagai kunci penghubung.

```
df.head()
```

	image	age_approx	anatom_site_general	lesion_id	sex	MEL	NV	BCC	AK	BKL	DF	VASC	SCC	UNK
0	ISIC_0000000	55.0	anterior torso	NaN	female	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
1	ISIC_0000001	30.0	anterior torso	NaN	female	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2	ISIC_0000002	60.0	upper extremity	NaN	female	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
3	ISIC_0000003	30.0	upper extremity	NaN	male	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
4	ISIC_0000004	80.0	posterior torso	NaN	male	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Gambar 3. 4 Hasil penggabungan *metadata* dan *ground truth*

Hasil penggabungan menghasilkan *dataset* berukuran 25.331 baris dan 14 kolom. Penggabungan ini dilakukan agar setiap citra memiliki informasi *metadata* pasien sekaligus label diagnosis yang sesuai. Selanjutnya, kolom target dibuat dengan mengambil nama kelas diagnosis yang bernilai 1 pada masing-masing baris. Berdasarkan hasil pengecekan, terdapat 8 kelas diagnosis pada dataset awal, yaitu NV, MEL, BKL, DF, SCC, BCC, VASC, dan AK.

```
label_columns = [
    'MEL', 'NV', 'BCC', 'AK',
    'BKL', 'DF', 'VASC', 'SCC', 'UNK'
]

df['target'] = df[label_columns].idxmax(axis=1)

print("Target label created successfully.")
```

... Target label created successfully.

```
df[['image', 'target']].head()
```

	image	target
0	ISIC_0000000	NV
1	ISIC_0000001	NV
2	ISIC_0000002	MEL
3	ISIC_0000003	NV
4	ISIC_0000004	MEL

```
df['target'].unique()
```

array(['NV', 'MEL', 'BKL', 'DF', 'SCC', 'BCC', 'VASC', 'AK'], dtype=object)

```
print("Number of classes:", df['target'].nunique())
```

Number of classes: 8

Gambar 3. 5 Hasil pembentukan label target diagnosis

3.1.2 Data Assessing

Pproses *data assessing* dilakukan untuk mengevaluasi struktur dan kualitas data. Hasil pengecekan menunjukkan bahwa dataset gabungan memiliki 25.331 data dan 15 kolom setelah kolom target ditambahkan. Kolom yang tersedia terdiri dari informasi identitas citra, metadata pasien, label diagnosis, dan target kelas penyakit.

```
[ ] # Dataset Shape

print("Dataset Shape:")
print(df.shape)

... Dataset Shape:
(25331, 15)

[ ] # Dataset Information


df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 25331 entries, 0 to 25330
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype
---  -
0   image                 25331 non-null  object
1   age_approx            24894 non-null  float64
2   anatom_site_general   22700 non-null  object
3   lesion_id             23247 non-null  object
4   sex                   24947 non-null  object
5   MEL                   25331 non-null  float64
6   NV                    25331 non-null  float64
7   BCC                   25331 non-null  float64
8   AK                    25331 non-null  float64
9   BKL                   25331 non-null  float64
10  DF                    25331 non-null  float64
11  VASC                  25331 non-null  float64
12  SCC                   25331 non-null  float64
13  UNK                   25331 non-null  float64
14  target                25331 non-null  object
dtypes: float64(10), object(5)
memory usage: 2.9+ MB
```

Gambar 3. 6 Struktur dataset hasil penggabungan

Pemeriksaan *missing value* dilakukan untuk mengetahui kolom mana saja yang masih memiliki data kosong. Hasil pemeriksaan menunjukkan bahwa terdapat missing value pada beberapa kolom metadata. Kolom *anatom_site_general* memiliki 2.631 data kosong atau sekitar 10,39% dari total data. Kolom *lesion_id*

memiliki 2.084 data kosong atau sekitar 8,23%. Kolom *age_approx* memiliki 437 data kosong atau sekitar 1,73%, sedangkan kolom *sex* memiliki 384 data kosong atau sekitar 1,52%. Sementara itu, kolom label diagnosis dan kolom target tidak memiliki *missing value*.



	Missing Values	Percentage (%)
anatom_site_general	2631	10.39
lesion_id	2084	8.23
age_approx	437	1.73
sex	384	1.52
image	0	0.00
MEL	0	0.00
NV	0	0.00
BCC	0	0.00
AK	0	0.00
BKL	0	0.00
DF	0	0.00
VASC	0	0.00
SCC	0	0.00
UNK	0	0.00
target	0	0.00

Gambar 3. 7 Hasil pemeriksaan missing value pada dataset

Pengecekan data duplikat juga dilakukan untuk memastikan tidak terdapat observasi yang tercatat lebih dari satu kali secara identik. Berdasarkan hasil pemeriksaan, tidak ditemukan data duplikat pada *dataset*, sehingga seluruh baris data dapat dipertahankan untuk tahap pengolahan berikutnya.

```
[ ] # Duplicate Check

duplicate_count = df.duplicated().sum()

print("Total Duplicate Data:", duplicate_count)

... Total Duplicate Data: 0
```

Gambar 3. 8 Hasil pemeriksaan data duplikat

Validasi keberadaan file citra dilakukan untuk memastikan setiap nilai pada kolom *image* dihubungkan dengan lokasi file gambar pada folder citra *ISIC 2019*. Kemudian dibuat kolom *image_path* untuk menyimpan alamat lengkap setiap citra dan kolom *image_exists* untuk mengecek apakah file citra benar-benar tersedia. Hasil validasi menunjukkan bahwa seluruh 25.331 citra memiliki file gambar yang tersedia, sehingga tidak terdapat metadata yang kehilangan pasangan citra.

```
[ ] # Image Validation Pipeline
# Create Image Path

df['image_path'] = df['image'].apply(
    lambda x: os.path.join(
        IMAGE_PATH,
        f"{x}.jpg"
    )
)


df[['image', 'image_path']].head()
```

	image	image_path
0	ISIC_0000000	/content/drive/MyDrive/DermaSight-DS/isic_2019...
1	ISIC_0000001	/content/drive/MyDrive/DermaSight-DS/isic_2019...
2	ISIC_0000002	/content/drive/MyDrive/DermaSight-DS/isic_2019...
3	ISIC_0000003	/content/drive/MyDrive/DermaSight-DS/isic_2019...
4	ISIC_0000004	/content/drive/MyDrive/DermaSight-DS/isic_2019...

Gambar 3. 9 Hasil validasi keberadaan file citra

Validasi *corrupted image* juga dilakukan untuk memastikan tidak ada file citra yang rusak atau gagal dibuka. Pemeriksaan dilakukan dengan membaca setiap file citra menggunakan fungsi *image validation*. Berdasarkan hasil pengecekan, tidak ditemukan citra yang rusak, dengan total *corrupted image* sebanyak 0. Hasil

ini menunjukkan bahwa seluruh citra pada *dataset* dapat digunakan untuk tahap analisis citra, *preprocessing*, dan persiapan *dataset modelling*.



```
[ ] ▶ # Corrupted Image Validation

corrupted_images = []

for path in df['image_path']:

    try:
        img = Image.open(path)
        img.verify()

    except:
        corrupted_images.append(path)

print("Total Corrupted Images:", len(corrupted_images))

... Total Corrupted Images: 0
```

Gambar 3. 10 Hasil pemeriksaan *corrupted image*

Hasil *data assessing* yang telah dilakukan dapat disimpulkan bahwa *dataset ISIC 2019* memiliki struktur data yang lengkap dari sisi hubungan metadata, label diagnosis, dan file citra. Permasalahan utama yang ditemukan berada pada *missing value* di beberapa kolom metadata, terutama lokasi anatomi lesi, *lesion ID*, usia, dan jenis kelamin. Namun, dataset tidak memiliki data duplikat, seluruh file citra tersedia, dan tidak ditemukan citra yang rusak. Oleh karena itu, dataset layak untuk dilanjutkan ke tahap *data cleaning* agar *missing value* dapat ditangani sebelum dilakukan analisis lebih lanjut.

3.2 Data Cleaning

Data cleaning dilakukan untuk menangani permasalahan kualitas data yang telah ditemukan pada tahap *data assessing*. Berdasarkan hasil pemeriksaan sebelumnya, *dataset ISIC 2019* masih memiliki *missing value* pada beberapa kolom *metadata*, yaitu *age_approx*, *sex*, *anatom_site_general*, dan *lesion_id*. Oleh karena itu, proses *cleaning* difokuskan untuk menangani nilai kosong tanpa menghapus baris data, karena setiap observasi masih memiliki citra medis yang valid dan dapat digunakan untuk analisis lebih lanjut.

Data cleaning diawali dengan membuat salinan dataset asli ke dalam variabel baru agar proses pembersihan tidak mengubah struktur data mentah secara

langsung. Pendekatan ini dilakukan untuk menjaga keamanan data asli, sehingga apabila terjadi kesalahan pada proses pengolahan, *dataset* awal tetap dapat digunakan kembali sebagai acuan.

Missing value pada kolom *anatom_site_general* dan *sex* ditangani dengan mengisi nilai kosong menggunakan kategori *unknown*. Penggunaan kategori ini dipilih karena informasi lokasi anatomi lesi dan jenis kelamin pasien tidak selalu tersedia pada *dataset* medis. Dengan memberikan label *unknown*, data tetap dapat dipertahankan tanpa menghilangkan observasi yang masih memiliki informasi penting pada kolom lain. Selain itu, kategori *unknown* juga membantu proses analisis mengenali bahwa data tersebut memang tidak tersedia pada sumber aslinya.

```
[ ] # Handle Missing Values

df_cleaned = df.copy()

# Fill anatomical site
df_cleaned['anatom_site_general'] = (
    df_cleaned['anatom_site_general']
    .fillna('unknown')
)

# Fill sex
df_cleaned['sex'] = (
    df_cleaned['sex']
    .fillna('unknown')
)

# Fill age
df_cleaned['age_approx'] = (
    df_cleaned['age_approx']
    .fillna(df_cleaned['age_approx'].median())
)


print("Missing value handling completed.")

... Missing value handling completed.
```

Gambar 3. 11 Proses penanganan *missing value* pada *metadata*

Missing value pada kolom *age_approx* ditangani menggunakan nilai median. Median dipilih karena lebih stabil terhadap nilai ekstrem dibandingkan rata-rata. Pada *dataset* medis, penggunaan median dianggap lebih aman karena distribusi usia pasien dapat memiliki variasi yang cukup besar. Dengan demikian, imputasi median dapat mempertahankan karakteristik umum usia pasien tanpa terlalu dipengaruhi oleh nilai usia yang terlalu rendah atau terlalu tinggi.

Setelah *missing value* pada *anatom_site_general*, *sex*, dan *age_approx* ditangani, masih terdapat *missing value* pada kolom *lesion_id*.



```
[ ] df_cleaned.isnull().sum()
```

...	0
image	0
age_approx	0
anatom_site_general	0
lesion_id	2084
sex	0
MEL	0
NV	0
BCC	0
AK	0
BKL	0
DF	0
VASC	0
SCC	0
UNK	0
target	0
image_path	0
image_exists	0

dtype: int64

Gambar 3. 12 Hasil pemeriksaan *missing value* setelah imputasi awal

Kolom *lesion_id* memiliki peran penting karena digunakan sebagai identitas lesi kulit dan menjadi dasar dalam proses *leakage-aware splitting* pada tahap data *preparation*. Oleh karena itu, *missing value* pada *lesion_id* tidak dihapus, tetapi diganti dengan identifier baru menggunakan format *unknown_lesion_x*. Setiap data

yang sebelumnya tidak memiliki *lesion_id* diberikan ID unik agar tetap dapat dibedakan satu sama lain.

```
missing_mask = df_cleaned['lesion_id'].isnull()

df_cleaned.loc[missing_mask, 'lesion_id'] = [
    f"unknown_lesion_{i}"
    for i in range(missing_mask.sum())
]

print("Missing lesion_id handled.")
```

... Missing lesion_id handled.

```
[ ] df_cleaned.isnull().sum()
```

...

	0
image	0
age_approx	0
anatom_site_general	0
lesion_id	0
sex	0
MEL	0
NV	0
BCC	0
AK	0
BKL	0
DF	0
VASC	0
SCC	0
UNK	0
target	0
image_path	0
image_exists	0

Gambar 3. 13 Hasil validasi *missing value* setelah penanganan *lesion ID*

Hasil validasi setelah proses penanganan *missing value* menunjukkan bahwa seluruh kolom pada dataset telah bebas dari nilai kosong. Kolom *age_approx*,

anatom_site_general, *sex*, dan *lesion_id* yang sebelumnya memiliki *missing value* berhasil dibersihkan. Dengan demikian, dataset sudah memiliki struktur metadata yang lebih lengkap dan konsisten untuk digunakan pada tahap analisis berikutnya. Setelah proses *missing value handling* selesai, dilakukan penyaringan kelas penyakit sesuai ruang lingkup proyek *DermaSight*. *Dataset ISIC 2019* pada awalnya memiliki beberapa kelas diagnosis, seperti MEL, NV, BCC, AK, BKL, DF, VASC, dan SCC. Namun, proyek ini hanya difokuskan pada tiga kelas utama, yaitu *Melanoma* (MEL), *Melanocytic Nevi* (NV), dan *Basal Cell Carcinoma* (BCC). Oleh karena itu, data dengan target di luar tiga kelas tersebut tidak digunakan pada analisis lanjutan.

```
[ ] # Final Target Scope Cleaning
selected_classes = [
    'MEL',
    'NV',
    'BCC'
]

df_model = df_cleaned[
    df_cleaned['target']
    .isin(selected_classes)
].copy()

print("Filtered Dataset Shape:")
print(df_model.shape)
```

... Filtered Dataset Shape:
(20720, 17)


```
[ ] # Cek Distribusi
df_model['target'].value_counts()
```

target	count
NV	12875
MEL	4522
BCC	3323

Gambar 3. 14 Hasil filtering *dataset* pada kelas MEL, NV, dan BCC

Hasil filtering menunjukkan bahwa jumlah data berkurang dari 25.331 data menjadi 20.720 data. Pengurangan ini terjadi bukan karena proses *cleaning*

menghapus data bermasalah, tetapi karena *dataset* difokuskan hanya pada tiga kelas yang menjadi ruang lingkup proyek. Distribusi kelas setelah filtering terdiri dari 12.875 data *Melanocytic Nevi* (NV), 4.522 data *Melanoma* (MEL), dan 3.323 data *Basal Cell Carcinoma* (BCC).



	Tahap	Jumlah Data	Jumlah Class	Keterangan
0	Raw Dataset	25331	8	Dataset asli ISIC_2019
1	After Cleaning	25331	8	Missing value dan validasi data
2	After Class Filtering	20720	3	Fokus pada class MEL, NV, dan BCC

Gambar 3. 15 Ringkasan hasil *data cleaning* dan *class filtering*


Proses data cleaning berhasil menghasilkan *dataset* yang lebih bersih, konsisten, dan sesuai dengan kebutuhan proyek. Jumlah data pada tahap *raw dataset* dan *after cleaning* tetap sama, yaitu 25.331 data, karena proses cleaning dilakukan dengan imputasi dan pengisian nilai default tanpa menghapus baris. Pengurangan jumlah data baru terjadi setelah tahap class filtering, yaitu menjadi 20.720 data dengan tiga kelas utama. *Dataset* hasil *cleaning* ini selanjutnya digunakan pada tahap *Exploratory Data Analysis* (EDA) untuk menganalisis distribusi kelas, *metadata* pasien, serta karakteristik citra medis pada kelas MEL, NV, dan BCC.

3.3 *Exploratory Data Analysis*

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dataset DermaSight setelah melalui tahap data cleaning dan class filtering. Pada tahap ini, analisis difokuskan pada tiga kelas penyakit kulit yang menjadi ruang lingkup proyek, yaitu Melanoma (MEL), Melanocytic Nevi (NV), dan Basal Cell Carcinoma (BCC). EDA dilakukan menggunakan kombinasi analisis statistik deskriptif dan visualisasi data agar pola distribusi data dapat dilihat secara lebih jelas sebelum dataset digunakan pada tahap preprocessing, feature engineering, dan data preparation.


3.3.1 Analisis Distribusi Kelas Target

Tahap awal EDA dilakukan dengan melihat distribusi kelas target pada dataset hasil filtering. Berdasarkan hasil analisis, jumlah data pada kelas *Melanocytic Nevi* (NV) sebanyak 12.875 data, *Melanoma* (MEL) sebanyak 4.522 data, dan *Basal Cell Carcinoma* (BCC) sebanyak 3.323 data. Distribusi ini menunjukkan bahwa kelas NV menjadi kelas paling dominan dibandingkan dua kelas lainnya.



Gambar 3. 16 Distribusi kelas target MEL, NV, dan BCC

Kelas NV memiliki proporsi terbesar, yaitu sekitar 62,1% dari total data. Kelas MEL memiliki proporsi sekitar 21,8%, sedangkan kelas BCC memiliki proporsi sekitar 16,0%. Kondisi ini menunjukkan bahwa *dataset* mengalami ketidakseimbangan kelas atau *class imbalance*, karena jumlah data pada kelas mayoritas jauh lebih besar dibandingkan kelas minoritas.




Gambar 3. 17 Persentase kelas target dan *imbalance ratio*


Hasil perhitungan *imbalance ratio* menunjukkan nilai sebesar 3,87. Artinya, jumlah data pada kelas terbesar hampir empat kali lebih banyak dibandingkan kelas terkecil. Kondisi ini perlu diperhatikan karena dapat menyebabkan model klasifikasi lebih cenderung mengenali kelas mayoritas, yaitu NV, dibandingkan MEL dan BCC apabila data langsung digunakan tanpa strategi penyeimbangan. Oleh karena itu, hasil analisis ini menjadi dasar penting untuk menentukan strategi balancing pada tahap data preparation.

3.3.2 Analisis Distribusi Usia Pasien

Analisis usia dilakukan menggunakan kolom *age_approx* untuk melihat karakteristik umur pasien pada dataset. Berdasarkan statistik deskriptif, jumlah data usia yang dianalisis sebanyak 20.720 data. Rata-rata usia pasien adalah 51,81 tahun, dengan nilai median 50 tahun. Usia minimum pada dataset adalah 0 tahun, sedangkan usia maksimum mencapai 85 tahun.




Gambar 3. 18 *Age Approx*




Gambar 3. 19 Distribusi usia pasien

Distribusi usia menunjukkan bahwa sebagian besar data berada pada kelompok usia dewasa hingga lansia. Nilai kuartil pertama berada pada usia 40 tahun, sedangkan kuartil ketiga berada pada usia 65 tahun. Hal ini menunjukkan bahwa sebagian besar pasien dalam *dataset* berada pada rentang usia menengah ke atas. Pada *boxplot* usia, terlihat adanya beberapa nilai ekstrem, terutama pada

kelompok usia sangat muda maupun usia lanjut. Namun, nilai tersebut tidak langsung dianggap sebagai kesalahan data karena pada dataset medis, variasi usia pasien masih memungkinkan terjadi dan tetap dapat merepresentasikan kondisi nyata.



Gambar 3. 20 *Boxplot* usia pasien pada dataset




Gambar 3. 21 *Boxplot* Age Approx

Hasil analisis usia ini menunjukkan bahwa metadata usia memiliki peran penting dalam memahami karakteristik penyakit kulit. Informasi usia juga dapat


membantu proses analisis lanjutan, terutama ketika dilakukan pengelompokan usia pada tahap feature engineering.

3.3.3 Analisis Distribusi Jenis Kelamin

Analisis jenis kelamin dilakukan untuk melihat komposisi pasien berdasarkan kolom *sex*. Hasil analisis menunjukkan bahwa pasien laki-laki berjumlah 10.686 data, pasien perempuan berjumlah 9.676 data, dan kategori unknown berjumlah 358 data. Berdasarkan hasil tersebut, jumlah pasien laki-laki sedikit lebih tinggi dibandingkan pasien perempuan.



Gambar 3. 22 Jumlah Distribusi jenis kelamin pasien




Gambar 3. 23 Distribusi jenis kelamin pasien

Meskipun terdapat selisih antara jumlah pasien laki-laki dan perempuan, distribusi keduanya masih tergolong cukup seimbang. Kategori *unknown* tetap dipertahankan karena berasal dari proses penanganan *missing value* pada tahap data


cleaning. Dengan mempertahankan kategori *unknown*, data tidak perlu dihapus dan tetap dapat digunakan dalam analisis tanpa kehilangan observasi penting.

3.3.4 Analisis Distribusi Lokasi Anatomi Lesi

Analisis lokasi anatomi lesi dilakukan menggunakan kolom *anatom_site_general*. Hasil analisis menunjukkan bahwa lokasi lesi paling banyak ditemukan pada *anterior torso* sebanyak 6.144 data, *lower extremity* sebanyak 4.134 data, *head/neck* sebanyak 2.778 data, *posterior torso* sebanyak 2.504 data, dan *upper extremity* sebanyak 2.407 data. Selain itu, terdapat kategori *unknown* sebanyak 2.293 data, *palms/soles* sebanyak 369 data, *lateral torso* sebanyak 48 data, dan *oral/genital* sebanyak 43 data.



Gambar 3. 24 Jumlah Distribusi lokasi anatomi lesi



Gambar 3. 25 Distribusi lokasi anatomi lesi

Distribusi tersebut menyatakan bahwa lesi kulit pada dataset paling banyak ditemukan pada area torso dan *extremity*. Area *anterior torso* menjadi lokasi dengan jumlah data tertinggi, sedangkan *oral/genital* dan *lateral torso* memiliki jumlah data paling sedikit. Pola ini menunjukkan bahwa distribusi lokasi anatomi tidak merata pada seluruh bagian tubuh. Informasi lokasi anatomi ini penting karena dapat digunakan untuk memahami kecenderungan munculnya lesi pada setiap kelas penyakit kulit.

3.3.5 Analisis Ukuran Citra

EDA juga dilakukan terhadap karakteristik citra medis. Analisis ukuran citra dilakukan pada 1.000 sampel gambar untuk mengetahui variasi dimensi citra yang tersedia pada dataset. Hasil analisis menunjukkan bahwa rata-rata lebar citra adalah 987,21 piksel, sedangkan rata-rata tinggi citra adalah 731,97 piksel. Nilai median lebar citra adalah 1024 piksel dan median tinggi citra adalah 768 piksel.

```
[ ] # Image Dimension Analysis
image_widths = []
image_heights = []
for path in df_model['image_path'][:1000]:
    img = Image.open(path)
    width, height = img.size
    image_widths.append(width)
    image_heights.append(height)

print(
    "Total analyzed images:",
    len(image_widths)
)


--- Total analyzed images: 1000

[ ] # Image Dimension Statistic
dimension_df = pd.DataFrame({
    'Width': image_widths,
    'Height': image_heights
})
dimension_df.describe()
```


	Width	Height
count	1000.000000	1000.000000
mean	987.212000	731.965000
std	84.689653	66.39797
min	576.000000	540.000000
25%	1024.000000	682.000000
50%	1024.000000	768.000000
75%	1024.000000	768.000000
max	1024.000000	1024.000000

Gambar 3. 26 Statistik ukuran citra medis

Sebagian besar citra memiliki ukuran yang relatif konsisten, yaitu mendekati 1024×768 piksel.




Gambar 3. 27 *Image height distribution*



Gambar 3. 28 *Image width distribution*

Namun, masih ditemukan variasi ukuran citra dengan jumlah *unique image dimension* sebanyak 84 variasi.



```
[ ] # Unique Image Dimension Analysis

unique_dimensions = len(
    set(zip(image_widths, image_heights))
)

print(
    "Unique Image Dimensions:",
    unique_dimensions
)


... Unique Image Dimensions: 84
```

Gambar 3. 29 Jumlah variasi dimensi citra


Hal ini menunjukkan bahwa meskipun mayoritas citra memiliki ukuran yang mirip, dataset tetap membutuhkan proses standardisasi ukuran sebelum digunakan pada tahap modeling. Oleh karena itu, *resize* citra menjadi salah satu tahapan penting pada *preprocessing* agar seluruh input gambar memiliki ukuran yang sama.

3.3.6 Analisis *Brightness* dan RGB Citra

Analisis *brightness* dilakukan pada 500 sampel citra untuk mengetahui variasi pencahayaan gambar. Berdasarkan hasil statistik deskriptif, rata-rata *brightness* citra adalah 156,86, dengan nilai minimum 75,56 dan nilai maksimum 225,50. Nilai median *brightness* sebesar 157,75 menunjukkan bahwa sebagian besar citra memiliki tingkat pencahayaan yang berada di sekitar nilai tengah tersebut.




Gambar 3. 30 Jumlah distribusi *brightness* citra



Gambar 3. 31 Distribusi *brightness* citra

Distribusi *brightness* menunjukkan adanya variasi pencahayaan antar citra, tetapi secara umum masih berada pada rentang yang cukup stabil. Variasi ini wajar ditemukan pada dataset citra medis karena gambar dapat diambil dari kondisi pencahayaan, perangkat, atau sumber akuisisi yang berbeda. Oleh karena itu, normalisasi piksel menjadi penting untuk membantu menyamakan skala nilai citra sebelum digunakan dalam proses pengembangan model.

Selain *brightness*, dilakukan juga analisis distribusi warna RGB.




Gambar 3. 32 Distribusi warna RGB pada citra

Hasil visualisasi menunjukkan bahwa intensitas warna *red*, *green*, dan *blue* memiliki pola distribusi yang berbeda. Analisis ini menunjukkan bahwa citra lesi kulit memiliki variasi warna yang dapat menjadi informasi penting pada proses klasifikasi penyakit kulit berbasis citra. Perbedaan karakteristik warna pada citra berpotensi membantu model dalam mengenali pola visual dari masing-masing kelas penyakit.


3.3.7 Analisis Hubungan *Metadata* dengan Kelas Target

Analisis *bivariate* dilakukan untuk melihat hubungan antara *metadata* pasien dengan kelas target. Analisis pertama dilakukan pada hubungan usia dan target menggunakan *boxplot*. Hasil visualisasi menunjukkan bahwa kelas BCC cenderung ditemukan pada kelompok usia yang lebih tua dibandingkan kelas lainnya, sedangkan kelas NV lebih banyak ditemukan pada kelompok usia yang relatif lebih muda. Sementara itu, kelas MEL berada pada rentang usia yang cukup luas, tetapi tetap banyak muncul pada kelompok usia dewasa hingga lansia.




Gambar 3. 33 Hubungan usia pasien dengan kelas target

Analisis berikutnya dilakukan pada hubungan jenis kelamin dan target. Hasil visualisasi menunjukkan bahwa pasien laki-laki memiliki jumlah kasus yang sedikit lebih tinggi dibandingkan perempuan pada sebagian besar kelas, terutama pada MEL dan BCC. Namun, perbedaan jumlah antara laki-laki dan perempuan tidak terlalu ekstrem sehingga faktor jenis kelamin lebih tepat dipahami sebagai informasi pendukung, bukan sebagai satu-satunya faktor pembeda kelas penyakit.



Gambar 3. 34 Hubungan jenis kelamin dengan kelas target

Analisis hubungan lokasi anatomi dengan target menunjukkan bahwa setiap kelas penyakit memiliki pola lokasi yang berbeda. Kelas NV banyak ditemukan pada area *anterior torso*, *lower extremity*, dan *posterior torso*. Sementara itu, kelas BCC lebih terlihat dominan pada area *head/neck* dibandingkan kelas lainnya. Pola ini menunjukkan bahwa lokasi anatomi lesi dapat menjadi informasi yang relevan dalam memahami karakteristik masing-masing kelas penyakit kulit.



Gambar 3. 35 Hubungan lokasi anatomi lesi dengan kelas target

Hasil EDA secara keseluruhan menunjukkan bahwa *dataset DermaSight* memiliki beberapa pola penting. Pertama, dataset mengalami *class imbalance* dengan dominasi kelas NV. Kedua, metadata usia, jenis kelamin, dan lokasi anatomi menunjukkan pola distribusi yang berbeda pada setiap kelas penyakit. Ketiga, citra medis memiliki ukuran, *brightness*, dan karakteristik warna yang cukup bervariasi sehingga membutuhkan preprocessing sebelum digunakan dalam pengembangan model. Hasil EDA ini menjadi dasar untuk tahap *explanatory analysis*, *preprocessing*, *feature engineering*, dan data preparation agar dataset akhir yang dihasilkan lebih siap digunakan pada proses modeling.

3.4 Explanatory Analysis Berdasarkan Business Questions

Explanatory analysis dilakukan untuk menjawab pertanyaan bisnis yang telah dirumuskan pada tahap awal proyek. Berbeda dengan *Exploratory Data Analysis* (EDA) yang berfokus pada eksplorasi pola data secara umum, *explanatory analysis* lebih diarahkan untuk menjelaskan temuan utama berdasarkan visualisasi dan hasil

analisis yang telah dilakukan. Pada proyek *DermaSight*, *explanatory analysis* digunakan untuk menjawab empat pertanyaan utama yang berkaitan dengan karakteristik metadata pasien, class imbalance, kualitas citra medis, serta peran preprocessing dan feature engineering dalam mempersiapkan dataset.

3.4.1 Karakteristik Distribusi Penyakit Kulit Berdasarkan *Metadata* Pasien

Pertanyaan bisnis pertama berkaitan dengan bagaimana karakteristik distribusi kelas *Melanoma* (MEL), *Melanocytic Nevi* (NV), dan *Basal Cell Carcinoma* (BCC) jika ditinjau berdasarkan metadata pasien, seperti usia, jenis kelamin, dan lokasi anatomi lesi. Berdasarkan hasil EDA, metadata pasien menunjukkan adanya pola yang berbeda pada setiap kelas penyakit.

Sebagian besar usia pada data berada pada kelompok usia dewasa hingga lansia. Rata-rata usia pasien pada dataset adalah 51,81 tahun, dengan median 50 tahun. Berdasarkan hubungan antara usia dan kelas target, kelas BCC cenderung muncul pada kelompok usia yang lebih tua dibandingkan kelas lainnya. Kelas NV lebih banyak ditemukan pada kelompok usia yang relatif lebih muda, sedangkan MEL memiliki sebaran usia yang lebih luas dan banyak muncul pada kelompok usia dewasa hingga lansia. Pola ini menunjukkan bahwa usia menjadi metadata yang penting untuk memahami karakteristik awal dari masing-masing kelas penyakit kulit. Pola tersebut dapat dilihat pada Gambar 3.18 dan Gambar 3.19 yang menunjukkan distribusi usia pasien secara umum, serta Gambar 3.33 yang menunjukkan hubungan antara usia pasien dengan kelas target.

Jenis kelamin pada dataset menunjukkan, data pasien laki-laki lebih banyak dibandingkan perempuan, yaitu 10.686 data laki-laki dan 9.676 data perempuan. Namun, selisih keduanya tidak terlalu besar sehingga distribusi gender masih dapat dikatakan cukup seimbang. Pada beberapa kelas, khususnya MEL dan BCC, jumlah kasus pada laki-laki terlihat sedikit lebih tinggi. Meskipun demikian, jenis kelamin tidak dapat dijadikan satu-satunya pembeda utama antar kelas karena pola distribusinya tidak terlalu ekstrem. Distribusi jenis kelamin pasien dapat dilihat pada Gambar 3.22 dan Gambar 3.23, sedangkan hubungan antara jenis kelamin dengan kelas target ditunjukkan pada Gambar 3.34.

Distribusi data lokasi anatomi menunjukkan bahwa lesi paling banyak ditemukan pada *anterior torso*, *lower extremity*, *head/neck*, *posterior torso*, dan

upper extremity. Area anterior torso menjadi lokasi dengan jumlah data tertinggi, yaitu 6.144 data. Pada hubungan antara lokasi anatomi dan target, kelas NV banyak ditemukan pada area torso dan *lower extremity*, sedangkan BCC lebih menonjol pada area *head/neck*. Sebaran lokasi anatomi lesi ditunjukkan pada Gambar 3.24 dan Gambar 3.25, sementara hubungan lokasi anatomi dengan kelas target dapat dilihat pada Gambar 3.35. Temuan ini menunjukkan bahwa lokasi anatomi lesi memiliki pola yang cukup informatif dan dapat digunakan untuk mendukung analisis karakteristik penyakit kulit.

Hasil dari ketiga metadata tersebut, dapat disimpulkan bahwa usia dan lokasi anatomi memiliki pola yang lebih terlihat dalam membedakan karakteristik kelas penyakit dibandingkan jenis kelamin. Metadata pasien tidak berdiri sebagai penentu diagnosis, tetapi dapat memberikan informasi pendukung yang berguna dalam memahami kecenderungan distribusi MEL, NV, dan BCC.

3.4.2 Kondisi *Class Imbalance* pada *Dataset*

Pertanyaan bisnis kedua berkaitan dengan apakah terdapat ketidakseimbangan distribusi kelas pada dataset MEL, NV, dan BCC. Berdasarkan hasil EDA, dataset menunjukkan kondisi class imbalance yang cukup jelas. Jumlah data kelas NV mencapai 12.875 data atau sekitar 62,1% dari total dataset. Sementara itu, kelas MEL memiliki 4.522 data atau sekitar 21,8%, dan kelas BCC memiliki 3.323 data atau sekitar 16,0%. Kondisi class imbalance tersebut dapat dilihat pada Gambar 3.16 dan Gambar 3.17, di mana kelas NV terlihat mendominasi dibandingkan kelas MEL dan BCC.

Perbedaan jumlah data tersebut menunjukkan bahwa kelas NV menjadi kelas mayoritas, sedangkan BCC menjadi kelas minoritas. Nilai *imbalance ratio* sebesar 3,87 menunjukkan bahwa jumlah kelas terbesar hampir empat kali lebih banyak dibandingkan kelas terkecil. Kondisi ini perlu diperhatikan karena dapat memengaruhi performa model klasifikasi apabila dataset langsung digunakan tanpa strategi penyeimbangan.

Apabila data tidak diseimbangkan, model berpotensi lebih banyak mempelajari pola dari kelas NV karena jumlah datanya jauh lebih dominan. Hal ini dapat menyebabkan model memiliki performa yang terlihat baik secara umum, tetapi kurang optimal dalam mengenali kelas MEL dan BCC. Padahal, dalam

konteks penyakit kulit, kelas seperti MEL dan BCC tetap penting untuk dikenali karena berkaitan dengan risiko klinis yang lebih tinggi.

Kondisi tersebut menunjukan *class imbalance* menjadi salah satu permasalahan utama yang harus ditangani pada tahap data preparation. Oleh karena itu, strategi *undersampling* diterapkan setelah proses *leakage-aware splitting* agar distribusi kelas pada *train*, *validation*, dan *test set* menjadi lebih seimbang tanpa menimbulkan risiko *data leakage*.

3.4.3 Profil Kualitas dan Karakteristik Citra Medis

Pertanyaan bisnis ketiga berkaitan dengan bagaimana profil kualitas serta karakteristik citra medis pada dataset MEL, NV, dan BCC. Berdasarkan hasil analisis citra, dataset memiliki kualitas yang cukup baik karena seluruh *image path* berhasil divalidasi dan tidak ditemukan *corrupted image*. Artinya, seluruh citra yang terhubung dengan *metadata* dapat dibuka dan digunakan untuk proses analisis maupun persiapan *dataset* modeling. Kelayakan data citra juga didukung oleh hasil validasi pada Gambar 3.9 dan Gambar 3.10, yang menunjukkan bahwa seluruh *image path* tersedia dan tidak ditemukan *corrupted image*.

Ukuran citra menunjukkan hasil analisis terhadap 1.000 sampel menunjukkan bahwa rata-rata lebar citra adalah 987,21 piksel dan rata-rata tinggi citra adalah 731,97 piksel. Median ukuran citra berada pada 1024×768 piksel, tetapi terdapat 84 variasi dimensi gambar. Hal ini menunjukkan bahwa meskipun sebagian besar citra memiliki ukuran yang relatif seragam, dataset tetap memiliki variasi dimensi yang perlu distandardisasi sebelum digunakan pada proses modeling. Variasi ukuran citra tersebut ditunjukkan pada Gambar 3.26, Gambar 3.27, Gambar 3.28, dan Gambar 3.29, sehingga proses *resize* menjadi penting untuk menyeragamkan ukuran input citra.

Hasil analisis *brightness* terhadap 500 sampel citra menunjukkan rata-rata brightness sebesar 156,86, dengan nilai minimum 75,56 dan maksimum 225,50. Nilai tersebut menunjukkan bahwa citra memiliki variasi tingkat pencahayaan, tetapi secara umum masih berada pada rentang yang cukup stabil. Variasi *brightness* ini wajar pada *dataset* citra medis karena gambar dapat berasal dari proses akuisisi yang berbeda. Distribusi *brightness* dapat dilihat pada Gambar 3.30 dan Gambar 3.31, sedangkan variasi kanal warna RGB ditunjukkan pada Gambar 3.32.

Distribusi warna RGB juga menunjukkan adanya variasi intensitas warna pada citra. Variasi warna ini penting karena citra lesi kulit mengandung informasi visual berupa perbedaan warna, tekstur, dan pola permukaan yang dapat membantu proses klasifikasi. Dengan demikian, citra medis pada dataset *DermaSight* dapat dikatakan layak digunakan, tetapi tetap membutuhkan *preprocessing* berupa *resize* dan normalisasi agar format input menjadi lebih konsisten.

3.4.4 Peran *Preprocessing* dan *Feature Engineering* dalam Meningkatkan Kualitas Dataset

Pertanyaan bisnis keempat berkaitan dengan bagaimana *preprocessing* dan *feature engineering* membantu meningkatkan kualitas dataset serta mendukung analisis karakteristik kelas MEL, NV, dan BCC. Berdasarkan hasil implementasi, *preprocessing* berperan penting dalam membuat *dataset* menjadi lebih konsisten, baik dari sisi metadata maupun citra.

Preprocessing pada metadata dilakukan melalui label *encoding* terhadap fitur kategorikal seperti *sex*, *anatom_site_general*, dan target. Transformasi ini membuat data kategorikal dapat direpresentasikan dalam bentuk numerik sehingga lebih mudah digunakan pada analisis lanjutan. Sementara itu, pada citra medis, *preprocessing* dilakukan melalui *preview resize* menjadi ukuran 224×224 piksel dan normalisasi nilai piksel ke rentang 0–1. Proses ini menunjukkan bahwa citra dapat distandardisasi ke format yang lebih sesuai untuk kebutuhan pipeline model.

Feature engineering dilakukan untuk membentuk fitur tambahan yang dapat memperkaya analisis. Fitur *age_group* dibentuk dari *age_approx* untuk mengelompokkan pasien ke dalam kelompok usia tertentu. Fitur ini membantu proses visualisasi dan interpretasi distribusi penyakit berdasarkan kelompok umur, tetapi tidak dijadikan fitur utama pada dataset final modeling karena lebih diarahkan untuk kebutuhan analisis deskriptif.

Fitur *risk_category* dibentuk dengan mengelompokkan kelas penyakit berdasarkan tingkat risiko, yaitu MEL dan BCC sebagai high risk serta NV sebagai low risk. Fitur ini berguna untuk analisis interpretatif dan severity grouping. Namun, fitur ini tidak digunakan sebagai fitur input training karena nilainya dibentuk langsung dari label target. Apabila fitur tersebut dimasukkan ke dalam

fitur model, maka dapat menimbulkan data leakage karena model seolah-olah memperoleh informasi jawaban dari target.

Fitur *site_risk_score* dibentuk berdasarkan lokasi anatomi lesi dengan memberikan skor risiko pada masing-masing kategori lokasi. Berbeda dengan *age_group* dan *risk_category*, fitur ini lebih aman dipertahankan dalam dataset final karena berasal dari metadata lokasi anatomi, bukan dari label target. Oleh karena itu, *site_risk_score* dapat digunakan sebagai metadata numerik tambahan untuk mendukung pengembangan model maupun *severity scoring*.

Hasil tersebut menunjukkan *preprocessing* dan *feature engineering* tidak hanya berfungsi untuk mengubah format data, tetapi juga membantu meningkatkan kualitas *dataset*, memperjelas pola analisis, dan mengurangi risiko kesalahan pada tahap modeling. Namun, tidak semua fitur hasil transformasi dimasukkan ke *dataset* final. Pemilihan fitur akhir tetap mempertimbangkan relevansi, fungsi analisis, dan potensi *data leakage*.

3.5 Preprocessing

Preprocessing dilakukan untuk menyiapkan dataset agar memiliki format yang lebih konsisten dan dapat digunakan pada tahap analisis lanjutan maupun persiapan modeling. Setelah proses data cleaning selesai dilakukan, dataset sudah tidak memiliki missing value dan telah difokuskan pada tiga kelas utama, yaitu *Melanoma* (MEL), *Melanocytic Nevi* (NV), dan *Basal Cell Carcinoma* (BCC). Oleh karena itu, tahap *preprocessing* pada bagian ini difokuskan pada transformasi fitur kategorikal ke dalam bentuk numerik serta simulasi *preprocessing* citra medis.

Tahap *preprocessing* perlu dilakukan karena dataset *DermaSight* tidak hanya terdiri dari data tabular berupa metadata pasien, tetapi juga data citra lesi kulit. *Metadata* seperti jenis kelamin, lokasi anatomi lesi, dan label target masih berbentuk kategorikal sehingga perlu diubah menjadi representasi numerik agar dapat diproses secara lebih mudah oleh algoritma komputasi. Sementara itu, citra medis juga perlu distandardisasi dari sisi ukuran dan rentang nilai piksel agar formatnya lebih siap digunakan pada pipeline pengembangan model.

3.5.1 Label Encoding pada Metadata

Tahap pertama *preprocessing* dilakukan dengan menerapkan *label encoding* pada beberapa kolom kategorikal. Kolom yang ditransformasi meliputi *sex*,

anatom_site_general, dan target. Proses label encoding mengubah kategori berbentuk teks menjadi angka, sehingga data dapat digunakan untuk kebutuhan analisis numerik, visualisasi lanjutan, maupun persiapan dataset modeling.

```
# Encode Sex
sex_encoder = LabelEncoder()

df_encoded['sex_encoded'] = sex_encoder.fit_transform(
    df_encoded['sex']
)

print(
    dict(
        zip(
            sex_encoder.classes_,
            sex_encoder.transform(
                sex_encoder.classes_
            )
        )
    )
)

... {'female': np.int64(0), 'male': np.int64(1), 'unknown': np.int64(2)}
```

Gambar 3. 36 *Encode sex*

```
# Encode Anatomical Site
site_encoder = LabelEncoder()

df_encoded['site_encoded'] = site_encoder.fit_transform(
    df_encoded['anatom_site_general']
)

print(
    dict(
        zip(
            site_encoder.classes_,
            site_encoder.transform(
                site_encoder.classes_
            )
        )
    )
)

... {'anterior torso': np.int64(0), 'head/neck': np.int64(1), 'lateral t
```

Gambar 3. 37 *Encode anatom_site_general*

```

▶ # Encode Target

target_encoder = LabelEncoder()

df_encoded['target_encoded'] = target_encoder.fit_transform(
    df_encoded['target']
)

print(
    dict(
        zip(
            target_encoder.classes_,
            target_encoder.transform(
                target_encoder.classes_
            )
        )
    )
)


... {'BCC': np.int64(0), 'MEL': np.int64(1), 'NV': np.int64(2)}

```

Gambar 3. 38 *Encode target*

Pada kolom target, hasil *encoding* menghasilkan representasi numerik untuk tiga kelas penyakit kulit, yaitu BCC, MEL, dan NV. Berdasarkan hasil label encoding, kelas BCC direpresentasikan dengan nilai 0, MEL dengan nilai 1, dan NV dengan nilai 2. Transformasi ini tidak mengubah makna kelas penyakit, tetapi hanya mengubah bentuk representasinya dari teks menjadi angka.

Selain kolom target, label encoding juga diterapkan pada kolom *sex* dan *anatom_site_general*. Kolom *sex* yang sebelumnya berisi kategori seperti *male*, *female*, dan *unknown* diubah menjadi nilai numerik. Kolom *anatom_site_general* yang berisi lokasi anatomi lesi juga diubah menjadi angka berdasarkan kategori lokasi masing-masing. Hasil transformasi ini membuat metadata lebih mudah digunakan pada proses analisis dan pengolahan data berikutnya.



```
# Check Encoding Result

df_encoded[[
    'sex',
    'sex_encoded',
    'anatom_site_general',
    'site_encoded',
    'target',
    'target_encoded'
]].head()
```

	sex	sex_encoded	anatom_site_general	site_encoded	target	target_encoded
0	female	0	anterior torso	0	NV	2
1	female	0	anterior torso	0	NV	2
2	female	0	upper extremity	8	MEL	1
3	male	1	upper extremity	8	NV	2
4	male	1	posterior torso	6	MEL	1

Gambar 3. 39 Sampel dataset setelah proses *label encoding*

Meskipun label target dikodekan menjadi angka, kolom target tetap berfungsi sebagai label atau output yang akan diprediksi, bukan sebagai fitur input model. Hal ini penting untuk menghindari data leakage, karena target tidak boleh digunakan sebagai variabel penjelas dalam proses training model. Dengan demikian, proses encoding pada target hanya digunakan untuk kebutuhan representasi label, bukan untuk dimasukkan sebagai fitur prediktor.

3.5.2 Image Preprocessing

Selain *preprocessing metadata*, dilakukan juga simulasi *preprocessing* terhadap citra medis. Tahap ini bertujuan untuk melihat bagaimana citra lesi kulit dapat disiapkan agar memiliki format yang seragam sebelum masuk ke pipeline modeling. Proses *image preprocessing* yang dilakukan meliputi *resize* citra dan normalisasi nilai piksel.

```
# Image Resize Preview

IMG_SIZE = 224

resized_img = cv2.resize(

    img_rgb,


    (IMG_SIZE, IMG_SIZE)

)

print(
    "Resized Image Shape:",
    resized_img.shape
)

... Resized Image Shape: (224, 224, 3)
```


Gambar 3. 40 Proses *resize* dan normalisasi citra



Gambar 3. 41 Perbandingan ukuran citra sebelum dan setelah *resize*

Resize dilakukan untuk mengubah ukuran citra menjadi 224×224 piksel. Ukuran ini digunakan agar seluruh citra memiliki dimensi yang sama, sehingga lebih mudah diproses oleh model berbasis citra. Berdasarkan hasil percobaan pada salah satu sampel citra, gambar yang semula memiliki ukuran asli $767 \times 1022 \times 3$ berhasil diubah menjadi $224 \times 224 \times 3$. Angka 3 menunjukkan bahwa citra tetap menggunakan tiga warna, yaitu *red*, *green*, dan *blue*.

Setelah *resize*, dilakukan normalisasi piksel dengan mengubah nilai piksel ke rentang 0 sampai 1. Pada citra asli, nilai piksel umumnya berada pada rentang 0 sampai 255. Normalisasi dilakukan dengan membagi nilai piksel dengan 255, sehingga skala nilai citra menjadi lebih kecil dan seragam. Hasil normalisasi menunjukkan bahwa nilai piksel minimum berada pada 0,0 dan nilai maksimum berada pada 1,0.



```
# Image Normalization Preview

normalized_img = resized_img / 255.0

print(
    "Minimum Pixel Value:",
    normalized_img.min()
)

print(
    "Maximum Pixel Value:",
    normalized_img.max()
)

... Minimum Pixel Value: 0.06666666666666667
Maximum Pixel Value: 1.0
```

Gambar 3. 42 Hasil normalisasi nilai piksel citra

Proses *resize* dan normalisasi ini penting karena citra pada dataset memiliki variasi ukuran dan pencahayaan. Dengan ukuran yang seragam dan nilai piksel yang telah dinormalisasi, data citra akan lebih siap digunakan pada tahap pengembangan model. Namun, pada tahap ini proses image preprocessing masih bersifat simulasi atau *preview* pada sampel citra, sehingga seluruh citra dalam folder dataset belum diubah secara permanen. *Preprocessing* citra secara penuh akan dilakukan pada pipeline modeling agar proses transformasi dapat diterapkan secara konsisten saat training, validation, dan testing.

3.5.3 Hasil *Preprocessing*

Hasil *preprocessing* menunjukkan bahwa metadata dan citra medis telah memiliki format yang lebih siap untuk digunakan pada tahap berikutnya. Pada *metadata*, fitur kategorikal telah berhasil direpresentasikan dalam bentuk numerik melalui *label encoding*. Pada citra medis, proses *resize* dan normalisasi berhasil

menunjukkan bahwa gambar dapat distandardisasi menjadi ukuran 224×224 piksel dengan nilai piksel pada rentang 0 sampai 1.

Meskipun demikian, tidak seluruh hasil *preprocessing* langsung dimasukkan sebagai fitur final untuk modeling. Kolom target yang telah *diencoding* tetap diposisikan sebagai label, bukan sebagai input model. Selain itu, *preprocessing* citra pada tahap ini digunakan untuk menunjukkan kesiapan *pipeline*, bukan untuk mengganti seluruh file citra asli secara permanen. Dengan demikian, tahap *preprocessing* berperan sebagai jembatan antara hasil *cleaning* dan tahap *feature engineering*, sekaligus memastikan bahwa data tabular dan citra sudah memiliki struktur yang lebih konsisten untuk proses data *preparation*.

3.6 Feature Engineering

Feature engineering dilakukan untuk membentuk fitur baru dari *metadata* yang sudah tersedia pada *dataset*. Tahap ini bertujuan untuk menghasilkan representasi data yang lebih informatif, sehingga pola karakteristik penyakit kulit dapat dianalisis dengan lebih mudah. Pada proyek *DermaSight*, *feature engineering* dilakukan setelah tahap *preprocessing*, sehingga *dataset* yang digunakan sudah bersih, konsisten, dan memiliki fitur kategorikal yang telah direpresentasikan dalam bentuk numerik. Pada tahap ini, terdapat tiga fitur utama yang dibentuk, yaitu *age_group*, *risk_category*, dan *site_risk_score*. Ketiga fitur tersebut memiliki fungsi yang berbeda. Fitur *age_group* dan *risk_category* lebih diarahkan untuk kebutuhan analisis, visualisasi, dan explanatory analysis. Sementara itu, fitur *site_risk_score* dipersiapkan sebagai fitur numerik tambahan yang dapat dipertahankan pada dataset final modeling karena berasal dari metadata lokasi anatomi lesi.

3.6.1 Pembentukan Fitur Age Group

Fitur *age_group* dibentuk berdasarkan kolom *age_approx*. Pembentukan fitur ini dilakukan dengan mengelompokkan usia pasien ke dalam beberapa kategori umur, yaitu *child*, *young_adult*, *adult*, dan *senior*. Pasien dengan usia kurang dari 18 tahun dikategorikan sebagai *child*, usia 18 sampai kurang dari 40 tahun sebagai *young_adult*, usia 40 sampai kurang dari 60 tahun sebagai *adult*, dan usia 60 tahun ke atas sebagai *senior*.

```
# Age Group Feature Engineering

def categorize_age(age):

    if age < 18:
        return 'child'

    elif age < 40:
        return 'young_adult'

    elif age < 60:
        return 'adult'

    else:
        return 'senior'


df_encoded['age_group'] = df_encoded['age_approx'].apply(
    categorize_age
)

df_encoded['age_group'].value_counts()

...
      count
age_group
adult      8772
senior     7580
young_adult 3714
child       654

dtype: int64
```


Gambar 3. 43 Hasil pembentukan fitur *age_group*



Gambar 3. 44 Distribusi kelompok usia pasien

Pengelompokan usia ini dilakukan agar distribusi umur pasien lebih mudah dianalisis dibandingkan menggunakan nilai usia numerik secara langsung. Dengan

adanya fitur *age_group*, pola distribusi penyakit kulit pada kelompok umur tertentu dapat diamati secara lebih sederhana dan mudah dipahami. Hasil pembentukan fitur menunjukkan bahwa kelompok adult memiliki jumlah data terbanyak, yaitu 8.772 data. Kelompok senior berjumlah 7.580 data, *young_adult* berjumlah 3.714 data, dan *child* berjumlah 654 data. Hasil ini menunjukkan bahwa sebagian besar pasien dalam *dataset* berada pada kelompok usia dewasa dan lansia.



```
[ ] ▶ # Encode Age Group

age_group_encoder = LabelEncoder()

df_encoded['age_group_encoded'] = (
    age_group_encoder.fit_transform(
        df_encoded['age_group']
    )
)

print(
    dict(
        zip(
            age_group_encoder.classes_,
            age_group_encoder.transform(
                age_group_encoder.classes_
            )
        )
    )
)

... {'adult': np.int64(0), 'child': np.int64(1), 'senior': np.int64(2), 'young_adult': np.int64(3)}
```

Gambar 3. 45 Hasil *encoding* fitur *age_group*

Setelah fitur *age_group* terbentuk, dilakukan juga *encoding* untuk mengubah kategori umur menjadi nilai numerik. Hasil encoding menunjukkan bahwa kategori adult direpresentasikan dengan nilai 0, child dengan nilai 1, senior dengan nilai 2, dan *young_adult* dengan nilai 3. *Encoding* ini membantu proses analisis numerik dan visualisasi hubungan antar fitur. Namun, fitur *age_group* pada proyek ini lebih difokuskan untuk kebutuhan interpretasi dan visualisasi, bukan sebagai fitur utama yang dipertahankan pada dataset final modeling.

3.6.2 Pembentukan Fitur *Risk Category*

Fitur *risk_category* dibentuk untuk mengelompokkan kelas penyakit berdasarkan tingkat risiko relatif. Pada proyek ini, kelas *Melanoma* (MEL) dan *Basal Cell Carcinoma* (BCC) dikategorikan sebagai *high_risk*, sedangkan *Melanocytic Nevi* (NV) dikategorikan sebagai *low_risk*. Pengelompokan ini dilakukan untuk membantu analisis karakteristik dataset berdasarkan tingkat risiko penyakit kulit secara lebih umum.

```
# Medical Risk Feature Engineering

# High-risk classes based on medical severity

high_risk_classes = [

    'MEL',
    'BCC'
]

df_encoded['risk_category'] = df_encoded['target'].apply(

    lambda x:

        'high_risk'

        if x in high_risk_classes

        else 'low_risk'

)

df_encoded['risk_category'].value_counts()


...
count

risk_category
low_risk    12875
high_risk    7845

dtype: int64
```

Gambar 3. 46 Hasil pembentukan fitur *risk_category*

Hasil pembentukan fitur menunjukkan bahwa kategori *low_risk* memiliki jumlah data sebanyak 12.875 data, sedangkan kategori *high_risk* memiliki jumlah data sebanyak 7.845 data. Dominasi kategori *low_risk* terjadi karena kelas NV merupakan kelas dengan jumlah data terbesar pada *dataset*.



Gambar 3. 47 Distribusi kategori risiko penyakit

Fitur *risk_category* kemudian *diencoding* menjadi bentuk numerik, dengan kategori *high_risk* direpresentasikan sebagai 0 dan *low_risk* sebagai 1. Meskipun fitur ini berguna untuk analisis interpretatif dan visualisasi, fitur *risk_category* tidak digunakan sebagai fitur input pada dataset final modeling. Hal ini karena *risk_category* dibentuk langsung dari label target, yaitu MEL, BCC, dan NV. Apabila fitur ini dimasukkan sebagai fitur *training*, maka model dapat memperoleh informasi yang seharusnya menjadi jawaban prediksi. Kondisi tersebut termasuk data leakage dan dapat menyebabkan hasil evaluasi model menjadi tidak objektif. Dengan demikian, fitur *risk_category* hanya digunakan untuk membantu *explanatory analysis* dan pembahasan *severity grouping*, bukan sebagai variabel prediktor pada model.

3.6.3 Pembentukan Fitur *Site Risk Score*

Fitur *site_risk_score* dibentuk berdasarkan kolom *anatom_site_general*, yaitu lokasi anatomi tempat lesi kulit berada. Fitur ini dibuat dengan mengubah kategori lokasi anatomi menjadi skor numerik yang merepresentasikan tingkat risiko relatif pada setiap area tubuh. Pendekatan ini digunakan agar informasi lokasi anatomi tidak hanya berbentuk kategori teks, tetapi juga memiliki representasi numerik yang lebih mudah digunakan pada analisis lanjutan.

```

SITE_RISK_SCORE = {
    "head/neck": 0.8,
    "torso": 0.7,
    "anterior torso": 0.7,
    "posterior torso": 0.7,
    "lateral torso": 0.6,
    "upper extremity": 0.5,
    "lower extremity": 0.5,
    "palms/soles": 0.9,
    "oral/genital": 0.85,
    "unknown": 0.6
}

df_encoded["site_risk_score"] = (
    df_encoded["anatom_site_general"]
    .map(SITE_RISK_SCORE)
)

df_encoded[
    [
        "anatom_site_general",
        "site_risk_score"
    ]
].head()

```

	anatom_site_general	site_risk_score
0	anterior torso	0.7
1	anterior torso	0.7
2	upper extremity	0.5
3	upper extremity	0.5
4	posterior torso	0.7

Gambar 3. 48 Proses pembentukan fitur *site_risk_score*

Skor risiko diberikan berdasarkan kategori lokasi anatomi. Area *palms/soles* diberikan skor 0,90, *oral/genital* sebesar 0,85, *head/neck* sebesar 0,80, *anterior torso* dan *posterior torso* sebesar 0,70, *lateral torso* sebesar 0,60, *upper extremity* dan *lower extremity* sebesar 0,50, sedangkan kategori *unknown* diberikan skor 0,60. Setelah proses mapping dilakukan, hasil pengecekan menunjukkan bahwa tidak terdapat nilai kosong pada fitur *site_risk_score*, sehingga seluruh data memiliki skor risiko lokasi anatomi.

```

df_encoded["site_risk_score"].isnull().sum()

```


np.int64(0)

Gambar 3. 49 alidasi missing value pada *site_risk_score*

Berbeda dengan *age_group* dan *risk_category*, fitur *site_risk_score* dipertahankan sebagai fitur yang dapat digunakan pada dataset final modeling. Hal ini karena *site_risk_score* dibentuk dari metadata lokasi anatomi lesi, bukan dari label target. Oleh karena itu, fitur ini lebih aman digunakan sebagai informasi tambahan dalam proses pengembangan model maupun *severity scoring*. Fitur *site_risk_score* juga memiliki nilai penting karena dapat merepresentasikan lokasi anatomi dalam bentuk numerik. Dengan adanya fitur ini, informasi lokasi lesi dapat lebih mudah diintegrasikan ke dalam proses perhitungan maupun pengembangan sistem, terutama apabila sistem tidak hanya melakukan klasifikasi penyakit, tetapi juga memberikan informasi tingkat risiko awal berdasarkan metadata pasien.

3.6.4 Analisis Hubungan Fitur Hasil *Feature Engineering*


Setelah fitur baru terbentuk, dilakukan analisis hubungan antar fitur untuk melihat apakah fitur tersebut dapat membantu menjelaskan karakteristik data. Visualisasi antara *age_group*, *risk_category*, dan target menunjukkan bahwa kelompok usia dewasa dan lansia memiliki jumlah kasus yang lebih dominan, terutama pada kategori penyakit berisiko tinggi. Hal ini sejalan dengan hasil EDA sebelumnya yang menunjukkan bahwa usia menjadi salah satu metadata yang cukup informatif dalam memahami distribusi penyakit kulit.



Gambar 3. 50 Hubungan *age_group*, *risk_category*, dan target

Analisis distribusi *risk_category* juga menunjukkan bahwa kategori *low_risk* lebih dominan dibandingkan *high_risk*, karena kelas NV memiliki jumlah data paling besar. Temuan ini mendukung hasil analisis *class imbalance* yang menunjukkan bahwa kelas NV menjadi kelas mayoritas pada *dataset*. Selain itu, distribusi *site_risk_score* menunjukkan bahwa sebagian besar lesi berada pada area dengan skor risiko menengah, terutama pada area torso dan *extremity*. Hal ini

menunjukkan bahwa fitur lokasi anatomi dapat memberikan informasi tambahan yang relevan dalam memahami persebaran lesi pada dataset.



Gambar 3. 51 *Heatmap* korelasi fitur hasil *preprocessing* dan *feature engineering*

Analisis korelasi juga dilakukan untuk melihat hubungan antara beberapa fitur numerik, seperti *age_approx*, *site_risk_score*, *risk_encoded*, dan *target_encoded*. Hasil *heatmap* korelasi digunakan untuk membantu memahami hubungan awal antar fitur, tetapi interpretasinya tetap dilakukan secara hati-hati karena beberapa fitur, seperti *risk_encoded* dan *target_encoded*, memiliki hubungan langsung dengan label target. Oleh karena itu, hasil korelasi ini digunakan sebagai bahan analisis, bukan sebagai dasar untuk memasukkan semua fitur ke dataset final modeling.

3.7 Data Preparation

Data preparation merupakan tahap akhir sebelum dataset digunakan pada proses pengembangan model. Setelah dataset melalui *data wrangling*, *data*

cleaning, *EDA*, *preprocessing*, dan *feature engineering*, data perlu disusun kembali agar siap digunakan untuk kebutuhan *training*, *validation*, dan *testing*. Pada proyek *DermaSight*, data *preparation* tidak hanya dilakukan dengan membagi data secara acak, tetapi juga mempertimbangkan risiko *data leakage* karena satu lesi kulit dapat memiliki lebih dari satu citra.

Tahap data preparation pada proyek ini terdiri dari beberapa proses utama, yaitu analisis duplikasi *lesion_id*, *leakage-aware splitting*, *leakage validation*, *class balancing* dengan *undersampling*, penyusunan dataset modeling, dan *export dataset* akhir. Proses ini dilakukan untuk memastikan bahwa dataset yang dihasilkan tidak hanya siap digunakan, tetapi juga memiliki struktur yang lebih aman dan objektif untuk tahap pengembangan model.

3.7.1 Analisis Duplikasi *Lesion ID*

Sebelum dilakukan pembagian data, terlebih dahulu dilakukan analisis terhadap kolom *lesion_id*. Kolom ini penting karena menunjukkan identitas lesi kulit pada dataset. Pada dataset *ISIC 2019*, satu lesi dapat memiliki lebih dari satu citra, sehingga terdapat kemungkinan beberapa gambar berbeda sebenarnya berasal dari lesi yang sama.

```
# PATIENT LEAKAGE ANALYSIS
# Lesion Duplicate Analysis


lesion_counts = (
    df_encoded['lesion_id']
    .value_counts()
)

duplicated_lesions = lesion_counts[
    lesion_counts > 1
]

print(
    "Total duplicated lesion_id:",
    len(duplicated_lesions)
)

... Total duplicated lesion_id: 3954
```

Gambar 3. 52 Duplikasi *Lesion ID*



```
# Max Image Per Lesion

print(
    "Maximum images per lesion:",
    lesion_counts.max()
)

... Maximum images per lesion: 31
```

Gambar 3. 53 Jumlah Maksimum citra per lesion

Hasil pengecekan menunjukkan bahwa terdapat 3.954 *lesion_id* yang memiliki lebih dari satu citra. Selain itu, jumlah maksimum citra pada satu *lesion_id* mencapai 31 citra. Kondisi ini menunjukkan bahwa pembagian data tidak aman apabila dilakukan secara acak pada level gambar, karena gambar dari lesi yang sama dapat masuk ke subset yang berbeda.

Apabila citra dari lesi yang sama masuk ke data training dan testing secara bersamaan, model dapat mengenali pola yang sudah pernah dilihat sebelumnya. Hal ini dapat menyebabkan hasil evaluasi terlihat terlalu baik, padahal performa tersebut tidak sepenuhnya merepresentasikan kemampuan model terhadap data baru. Oleh karena itu, proses pembagian dataset dilakukan dengan pendekatan *leakage-aware splitting* berbasis *lesion_id*.

3.7.2 *Leakage-Aware Splitting*

Leakage-aware splitting dilakukan dengan menjadikan *lesion_id* sebagai dasar pembagian data. Artinya, seluruh citra yang berasal dari lesi yang sama ditempatkan pada subset yang sama, baik *train*, *validation*, maupun *test*. Pendekatan ini digunakan untuk menjaga agar tidak ada informasi dari lesi yang sama tersebar ke subset lain.

```

# Split Dataset
# Lesion-level Split

unique_lesions = final_df['lesion_id'].unique()

train_lesions, temp_lesions = train_test_split(

    unique_lesions,

    test_size=0.2,

    random_state=42
)

val_lesions, test_lesions = train_test_split(

    temp_lesions,

    test_size=0.5,

    random_state=42
)

# Create Split DataFrame

train_df = final_df[
    final_df['lesion_id'].isin(train_lesions)
].copy()

val_df = final_df[
    final_df['lesion_id'].isin(val_lesions)
].copy()

test_df = final_df[
    final_df['lesion_id'].isin(test_lesions)
].copy()

```

Gambar 3. 54 Proses *leakage-aware splitting* berbasis *lesion_id*

Dataset dibagi menjadi tiga subset utama, yaitu *training set*, *validation set*, dan *testing set*. *Training set* digunakan sebagai data utama untuk proses pelatihan model, *validation set* digunakan untuk membantu proses validasi dan pemilihan konfigurasi model, sedangkan *testing set* digunakan sebagai data evaluasi akhir.

```
# Check Split Shape

print("Before Undersampling")

print("Train Shape :", train_df.shape)

print("Validation Shape :", val_df.shape)

print("Test Shape :", test_df.shape)

... Before Undersampling
Train Shape : (16600, 25)
Validation Shape : (2021, 25)
Test Shape : (2099, 25)
```

Gambar 3. 55 Jumlah data *train*, *validation*, dan *test* sebelum *balancing*

Hasil pembagian sebelum dilakukan *balancing* menghasilkan 16.600 data pada *training set*, 2.021 data pada *validation set*, dan 2.099 data pada *testing set*. Pembagian ini menjadi dasar awal sebelum dilakukan proses penyeimbangan kelas. Meskipun jumlah data pada setiap subset sudah terbagi, distribusi kelas di dalamnya masih mengikuti kondisi awal dataset yang tidak seimbang.

3.7.3 *Leakage Validation*

Setelah proses *splitting* selesai, dilakukan validasi *data leakage* untuk memastikan bahwa tidak ada *lesion_id* yang muncul pada lebih dari satu subset. Validasi dilakukan dengan membandingkan daftar *lesion_id* pada *training set*, *validation set*, dan *testing set*.

```
# Leakage Check

train_lesions = set(train_df['lesion_id'])

val_lesions = set(val_df['lesion_id'])

test_lesions = set(test_df['lesion_id'])

print(
    "Train-Val Leakage:",
    len(train_lesions & val_lesions)
)

print(
    "Train-Test Leakage:",
    len(train_lesions & test_lesions)
)

print(
    "Val-Test Leakage:",
    len(val_lesions & test_lesions)
)

... Train-Val Leakage: 0
Train-Test Leakage: 0
Val-Test Leakage: 0
```

Gambar 3. 56 Hasil validasi *data leakage* antar subset

Hasil validasi menunjukkan bahwa nilai *Train-Val Leakage* adalah 0, *Train-Test Leakage* adalah 0, dan *Val-Test Leakage* adalah 0. Hasil ini membuktikan bahwa tidak terdapat *lesion_id* yang sama pada subset yang berbeda. Dengan demikian, strategi *leakage-aware splitting* berhasil diterapkan dengan baik. Validasi ini menjadi salah satu bagian penting dalam data preparation karena memastikan bahwa proses evaluasi model nantinya dapat dilakukan secara lebih objektif. *Dataset* yang bebas dari data leakage akan memberikan gambaran performa model yang lebih realistis terhadap data baru.

3.7.4 Class Balancing dengan Undersampling

```
... Train Distribution
target
NV      10341
MEL      3595
BCC      2664
Name: count, dtype: int64

Validation Distribution
target
NV       1260
MEL       428
BCC       333
Name: count, dtype: int64

Test Distribution
target
NV       1274
MEL       499
BCC       326
Name: count, dtype: int64
```

Gambar 3. 57 Distribusi kelas sebelum *undersampling*

Berdasarkan hasil EDA, dataset *DermaSight* mengalami *class imbalance* karena kelas NV memiliki jumlah data yang jauh lebih besar dibandingkan MEL dan BCC. Ketidakeimbangan ini perlu ditangani agar model tidak terlalu dominan mempelajari pola dari kelas mayoritas. Oleh karena itu, dilakukan *class balancing* menggunakan metode *undersampling*.

```
def undersample(df, seed=42):

    n = min(
        Counter(df['target']).values()
    )

    parts = [

        df[df['target'] == c]
        .sample(n, random_state=seed)

        for c in df['target'].unique()
    ]

    return (

        pd.concat(parts)

        .sample(frac=1, random_state=seed)

        .reset_index(drop=True)
    )
```

Gambar 3. 58 Proses *class balancing* menggunakan *undersampling*

Undersampling dilakukan setelah proses *splitting*, bukan sebelum *splitting*. Keputusan ini penting karena *balancing* sebelum *splitting* dapat meningkatkan risiko *data leakage* dan membuat distribusi data menjadi kurang objektif. Dengan melakukan *undersampling* setelah *splitting*, setiap subset tetap independen dan proses penyeimbangan kelas tidak mencampurkan informasi antar subset. Pada *training set*, jumlah data diseimbangkan menjadi 2.664 data untuk masing-masing kelas, sehingga total *training set* setelah *balancing* menjadi 7.992 data. Pada *validation set*, masing-masing kelas memiliki 333 data, sehingga total *validation set* menjadi 999 data. Sementara itu, pada *testing set*, masing-masing kelas memiliki 326 data, sehingga total *testing set* menjadi 978 data.

```

# Check Balanced Shape

print("After Undersampling")

for name, df_ in [

    ("Train", df_train_bal),

    ("Validation", df_val_bal),

    ("Test", df_test_bal)

]:

    counts = Counter(df_['target'])

    print(

        f"{name:<10}: "

        f"{len(df_):,} total "

        f"({len(df_)//len(counts):,}/class)"

    )

```


```

... After Undersampling
Train      : 7,992 total (2,664/class)
Validation: 999 total (333/class)
Test       : 978 total (326/class)

```

Gambar 3. 59 Jumlah data setelah *undersampling* pada setiap subset

Hasil *undersampling* menunjukkan bahwa distribusi kelas pada setiap subset telah menjadi seimbang dengan rasio 1:1:1 antara kelas BCC, MEL, dan NV. Dengan kondisi ini, dataset lebih siap digunakan untuk proses modeling karena setiap kelas memiliki jumlah data yang sama pada masing-masing subset.



Gambar 3. 60 Distribusi kelas final setelah *undersampling*

3.7.5 Penyusunan *Dataset Modeling*

Setelah proses *splitting* dan *balancing* selesai, dataset disusun kembali ke dalam format yang lebih sederhana dan fokus pada kebutuhan modeling. Penyusunan *dataset modeling* dilakukan dengan memilih kolom yang relevan dan menghindari fitur yang berpotensi menyebabkan *data leakage*.

```

# AI Modeling Dataframe

ai_columns = [
    'image_path',
    'target',
    'image',
    'anatom_site_general',
    'lesion_id',
    'site_risk_score'
]

train_ai_df = df_train_bal[
    ai_columns
].copy()

val_ai_df = df_val_bal[
    ai_columns
].copy()

test_ai_df = df_test_bal[
    ai_columns
].copy()

train_ai_df = train_ai_df.rename(columns={
    'target': 'class_name',
    'image': 'image_id'
})

val_ai_df = val_ai_df.rename(columns={
    'target': 'class_name',
    'image': 'image_id'
})

test_ai_df = test_ai_df.rename(columns={
    'target': 'class_name',
    'image': 'image_id'
})

train_ai_df.columns

*** Index(['image_path', 'class_name', 'image_id', 'anatom_site_general',
        'lesion_id', 'site_risk_score'],
        dtype='object')

train_ai_df.head()

```

	image_path	class_name	image_id	anatom_site_general	lesion_id	site_risk_score
0	/content/drive/MyDrive/DermaSight-DS/isic_2019...	NV	ISIC_0028440	lower extremity	HAM_0001461	0.5
1	/content/drive/MyDrive/DermaSight-DS/isic_2019...	MEL	ISIC_0015180_downsampled	head/neck	unknown_lesion_1841	0.8
2	/content/drive/MyDrive/DermaSight-DS/isic_2019...	MEL	ISIC_0032975	posterior torso	HAM_0001847	0.7
3	/content/drive/MyDrive/DermaSight-DS/isic_2019...	MEL	ISIC_0061833	head/neck	BCN_0004801	0.8
4	/content/drive/MyDrive/DermaSight-DS/isic_2019...	BCC	ISIC_0072060	head/neck	BCN_0000332	0.8

Gambar 3. 61 Struktur dataset modeling akhir

Kolom yang dipertahankan pada dataset modeling meliputi *image_path*, *class_name*, *image_id*, *anatom_site_general*, *lesion_id*, dan *site_risk_score*. Kolom *image_path* digunakan sebagai alamat citra yang akan diproses dalam pipeline model. Kolom *class_name* digunakan sebagai label target, sedangkan *image_id* dan *lesion_id* digunakan sebagai identitas data. Kolom *anatom_site_general* dan *site_risk_score* dipertahankan sebagai metadata pendukung.

Tidak semua fitur hasil *preprocessing* dan *feature engineering* dimasukkan ke dataset final modeling. Fitur seperti *age_group* lebih digunakan untuk kebutuhan analisis dan visualisasi distribusi usia. Sementara itu, *risk_category* tidak

dimasukkan sebagai fitur input model karena dibentuk langsung dari label target. Jika fitur tersebut digunakan sebagai input model, maka dapat terjadi *data leakage* karena model memperoleh informasi yang terlalu dekat dengan jawaban prediksi.

Dataset modeling disusun secara selektif agar tetap informatif tetapi tidak membocorkan informasi target. Pemilihan kolom ini juga membuat dataset akhir lebih ringkas, mudah digunakan, dan sesuai untuk pengembangan model klasifikasi citra maupun *severity scoring*.

3.7.6 Export Dataset

Tahap terakhir dalam *data preparation* adalah export dataset ke dalam file terpisah. Dataset hasil *balancing* diekspor menjadi tiga file, yaitu *train.csv*, *val.csv*, dan *test.csv*. Pemisahan file ini dilakukan agar pipeline modeling dapat langsung menggunakan data sesuai subset masing-masing tanpa perlu melakukan pembagian ulang.



```
# Export Dataset

train_ai_df.to_csv(
    'train.csv',
    index=False
)

val_ai_df.to_csv(
    'val.csv',
    index=False
)

test_ai_df.to_csv(
    'test.csv',
    index=False
)

print("Dataset exported successfully.")

... Dataset exported successfully.

files.download('train.csv')
files.download('val.csv')
files.download('test.csv')
```

Gambar 3. 62 Hasil *export dataset train, validation, dan test*

File train.csv berisi data training yang telah diseimbangkan, *val.csv* berisi data validation, dan *test.csv* berisi data testing. Ketiga file tersebut memiliki struktur kolom yang sama sehingga lebih mudah digunakan pada tahap pengembangan model. Dengan adanya *export dataset* ini, hasil data *preparation* menjadi lebih terorganisasi dan siap digunakan oleh tim pengembangan model.


Tahap data *preparation* secara keseluruhan berhasil menghasilkan dataset yang bebas dari *data leakage*, memiliki distribusi kelas yang seimbang, dan telah dipisahkan ke dalam subset *train*, *validation*, dan *test*. Tahap ini menjadi bagian penting karena kualitas pembagian data akan sangat memengaruhi objektivitas proses *training* dan evaluasi model pada tahap berikutnya.

3.8 Final Dataset Summary dan Data Dictionary

Tahap terakhir dalam implementasi proyek *DermaSight* adalah penyusunan ringkasan *dataset* akhir dan data dictionary. Tahap ini dilakukan untuk mendokumentasikan hasil akhir dari seluruh proses pengolahan data, mulai dari *data wrangling*, *data cleaning*, *exploratory data analysis*, *preprocessing*, *feature engineering*, hingga *data preparation*. Dengan adanya ringkasan dataset akhir, struktur data yang akan digunakan pada tahap pengembangan model dapat dipahami dengan lebih jelas.

Dataset akhir yang dihasilkan telah melalui proses *leakage-aware splitting* berbasis *lesion_id*, *validasi data leakage*, serta *class balancing* menggunakan *undersampling*. Hasil akhir dari proses tersebut berupa tiga subset data, yaitu *training set*, *validation set*, dan *testing set*. Ketiga subset ini telah disusun dalam format yang sama dan diekspor ke dalam file *train.csv*, *val.csv*, dan *test.csv*.

3.8.1 Final Dataset Summary



	Dataset	Rows	Classes
0	train	7992	3
1	val	999	3
2	test	978	3

Gambar 3. 63 Ringkasan jumlah data final pada setiap subset

Berdasarkan hasil *data preparation*, *dataset* akhir memiliki total 9.969 data yang terbagi ke dalam tiga subset. *Training set* memiliki 7.992 data, *validation set* memiliki 999 data, dan *testing set* memiliki 978 data. Jumlah data pada setiap subset telah diseimbangkan sehingga masing-masing kelas memiliki jumlah data yang sama.

Tabel 3. 1 Ringkasan jumlah data akhir pada setiap subset.

Subset	Jumlah Data	Jumlah Kelas	Distribusi Kelas
<i>Training Set</i>	7.992	3	BCC = 2.664, MEL = 2.664, NV = 2.664
<i>Validation Set</i>	999	3	BCC = 333, MEL = 333, NV = 333
<i>Testing Set</i>	978	3	BCC = 326, MEL = 326, NV = 326
Total	9.969	3	<i>Balanced</i>

Berdasarkan tabel tersebut, dapat dilihat bahwa setiap subset telah memiliki distribusi kelas yang seimbang dengan rasio 1:1:1 antara kelas BCC, MEL, dan NV. Kondisi ini menunjukkan bahwa proses *undersampling* berhasil mengurangi dominasi kelas mayoritas NV yang sebelumnya ditemukan pada tahap EDA. Selain seimbang dari sisi kelas, dataset akhir juga telah divalidasi agar bebas dari data leakage. Hasil validasi menunjukkan bahwa tidak terdapat *lesion_id* yang sama pada subset *training*, *validation*, maupun *testing*. Dengan demikian, setiap subset bersifat independen dan dapat digunakan secara lebih objektif pada proses pengembangan maupun evaluasi model.

```

***
      Column Name      Description  Data Type
0      image_path      Path lokasi file citra medis      object
1      class_name      Label kelas penyakit kulit (MEL, NV, BCC)      object
2      image_id      Unique identifier untuk setiap gambar      object
3      anatom_site_general      Lokasi anatomi umum tempat lesi berada      object
4      lesion_id      Unique identifier untuk setiap lesi kulit      object
5      site_risk_score      Skor numerik risiko berdasarkan lokasi anatomi...      float64

```

Gambar 3. 64 Sampel struktur dataset final untuk modeling

Dataset final juga telah disusun dengan kolom yang lebih ringkas dan sesuai kebutuhan modeling. Kolom yang dipertahankan terdiri dari *image_path*,

class_name, *image_id*, *anatom_site_general*, *lesion_id*, dan *site_risk_score*. Pemilihan kolom dilakukan secara selektif agar dataset tetap informatif, tetapi tidak membawa fitur yang berpotensi menyebabkan data leakage.

3.8.2 Struktur Dataset Final

Dataset final memiliki enam kolom utama yang digunakan untuk mendukung proses pengembangan model. Struktur ini dibuat sama pada file *train.csv*, *val.csv*, dan *test.csv* agar *pipeline* modeling dapat membaca data dengan format yang konsisten.

Tabel 3. 2 Struktur kolom pada dataset final.

No	Nama Kolom	Tipe Data	Deskripsi	Peran dalam Dataset
1	<i>image_path</i>	<i>Object/String</i>	lokasi file citra lesi kulit pada folder dataset.	Input citra
2	<i>class_name</i>	<i>Object/String</i>	Label kelas penyakit kulit, yaitu BCC, MEL, NV.	Target/label
3	<i>image_id</i>	<i>Object/String</i>	Identitas unik citra berdasarkan nama file gambar.	Identitas data
4	<i>anatom_site_general</i>	<i>Object/String</i>	Informasi lokasi anatomi lesi kulit pada tubuh pasien.	Metadata pendukung
5	<i>lesion_id</i>	<i>Object/String</i>	Identitas lesi kulit yang digunakan untuk mencegah data leakage saat splitting.	Identitas lesi
6	<i>site_risk_score</i>	<i>Float</i>	Skor risiko lokasi anatomi lesi berdasarkan kategori lokasi tubuh.	Metadata numerik pendukung

Berdasarkan struktur tersebut, *image_path* menjadi kolom utama untuk mengakses citra medis yang akan digunakan sebagai input model. Kolom *class_name* berfungsi sebagai target atau label yang akan diprediksi. Sementara itu, *image_id* dan *lesion_id* digunakan sebagai identitas data.

Kolom *anatom_site_general* dan *site_risk_score* dipertahankan sebagai metadata pendukung. *anatom_site_general* memberikan informasi lokasi anatomi lesi, sedangkan *site_risk_score* merepresentasikan lokasi anatomi dalam bentuk numerik. Fitur *site_risk_score* dipertahankan karena berasal dari metadata lokasi lesi, bukan dari label target, sehingga lebih aman digunakan sebagai informasi tambahan dalam pengembangan model maupun *severity scoring*.

3.8.3 Fitur yang Tidak Dimasukkan ke Dataset Final

Tidak semua fitur hasil *preprocessing* dan *feature engineering* dimasukkan ke dalam dataset final. Beberapa fitur hanya digunakan untuk kebutuhan analisis, visualisasi, dan *explanatory analysis*. Hal ini dilakukan agar dataset final tetap fokus pada kebutuhan modeling dan tidak mengandung fitur yang berpotensi menyebabkan data leakage.

Fitur *age_group* tidak dimasukkan ke dataset final karena pada proyek ini lebih difokuskan untuk membantu analisis distribusi usia pasien dan visualisasi hubungan usia dengan kelas penyakit. Fitur ini tetap berguna pada tahap EDA dan *explanatory analysis*, tetapi tidak menjadi fitur utama pada dataset modeling akhir. Fitur *risk_category* juga tidak dimasukkan ke dataset final sebagai fitur input model. Fitur ini dibentuk langsung dari label target, yaitu MEL dan BCC sebagai *high_risk*, sedangkan NV sebagai *low_risk*. Karena berasal dari target, penggunaan *risk_category* sebagai fitur *training* dapat menyebabkan *data leakage*. Oleh karena itu, fitur ini hanya digunakan untuk kebutuhan interpretasi risiko dan *severity grouping*, bukan sebagai variabel prediktor. Selain itu, kolom hasil encoding seperti *target_encoded*, *sex_encoded*, *site_encoded*, dan *risk_encoded* tidak dipertahankan pada dataset final utama. Kolom-kolom tersebut digunakan pada tahap *preprocessing* dan analisis korelasi, tetapi tidak semuanya diperlukan dalam struktur *dataset* akhir. Pemilihan kolom final dilakukan dengan mempertimbangkan fungsi, relevansi, dan keamanan terhadap kebocoran informasi target.

BAB IV

PENUTUP

4.1 Kesimpulan

Kesimpulan dari final project ini adalah bahwa proyek *DermaSight* berhasil melakukan analisis dan persiapan *dataset* penyakit kulit berbasis citra medis menggunakan *dataset ISIC 2019*. *Dataset* awal yang terdiri dari *metadata*, *ground truth*, dan citra lesi kulit berhasil digabungkan dan dibersihkan sehingga dapat digunakan untuk analisis lebih lanjut. Setelah dilakukan penyaringan sesuai ruang lingkup proyek, *dataset* difokuskan pada tiga kelas utama, yaitu *Melanoma* (MEL), *Melanocytic Nevi* (NV), dan *Basal Cell Carcinoma* (BCC), dengan total 20.720 data.

Hasil analisis menunjukkan bahwa *dataset* memiliki permasalahan *class imbalance*, dengan kelas NV sebagai kelas mayoritas, sedangkan MEL dan BCC memiliki jumlah data yang lebih sedikit. Selain itu, *metadata* pasien seperti usia, jenis kelamin, dan lokasi anatomi lesi menunjukkan pola distribusi yang berbeda pada masing-masing kelas penyakit. Dari sisi citra, *dataset* memiliki variasi ukuran, *brightness*, dan distribusi warna RGB, sehingga diperlukan *proses preprocessing* agar data lebih konsisten sebelum digunakan pada tahap modeling.

Proyek ini juga berhasil menghasilkan *dataset* akhir yang lebih siap digunakan untuk pengembangan model. Proses *leakage-aware splitting* dilakukan berdasarkan *lesion_id* untuk mencegah data *leakage* antar subset. Setelah itu, dilakukan *undersampling* sehingga distribusi kelas pada *data training*, *validation*, dan *testing* menjadi seimbang. *Dataset* final kemudian diekspor ke dalam file *train.csv*, *val.csv*, dan *test.csv* dengan struktur yang lebih ringkas dan dilengkapi *data dictionary*. Dengan demikian, proyek ini telah menghasilkan *dataset* modeling yang bersih, terstruktur, seimbang, dan bebas dari *data leakage*.

4.2 Saran


Berdasarkan hasil proyek yang telah dilakukan, terdapat beberapa saran untuk pengembangan proyek *DermaSight* selanjutnya, yaitu:

1. Evaluasi model pada tahap berikutnya sebaiknya tidak hanya menggunakan akurasi, tetapi juga metrik lain seperti *precision*, *recall*, *f1-score*, dan *confusion matrix* agar performa model pada setiap kelas penyakit dapat dianalisis secara lebih detail.
2. Fitur *site_risk_score* dapat dikembangkan lebih lanjut untuk mendukung *severity scoring*, tetapi masih perlu divalidasi menggunakan referensi medis atau masukan dari tenaga ahli agar penggunaannya lebih sesuai dengan konteks klinis.
3. Dataset dapat dikembangkan dengan menambahkan kelas penyakit kulit lain dari *ISIC 2019* agar sistem *DermaSight* memiliki cakupan klasifikasi yang lebih luas.


DAFTAR PUSTAKA

MvD, A. (2019). ISIC 2019 *skin lesion dataset* [Data set]. Kaggle.
<https://www.kaggle.com/datasets/andrewmvd/isic-2019>


LAMPIRAN




Lampiran 1 Streamlit Home




Lampiran 2 Steamlit Dashboard




Lampiran 3 Streamlit Dataset Overview




Lampiran 4 Bisness Question Analysis




Lampiran 5 Streamlit Feature Engineering



Lampiran 6 Streamlit Correlation Analysis



Lampiran 7 Streamlit Data Preparation



Lampiran 8 Streamlit Dataset Documentation